Data Science e Big Data na Indústria

Aula 01 - conceitos, prática e revisão

Guia para estudantes do campus. Base: Aula 01, Prof. Me Daniel Vieira, PDF de 63 páginas. Revisado em 06/10/2026.

Como estudar

Leia o resumo, identifique o objetivo, observe as figuras originais no campus e tente a prática antes de conferir. Abra o notebook em Jupyter ou Colab, selecione Python e execute primeiro Preparar os dados. Os tempos do campus incluem leitura e atividades; não são duração de áudio.

Origem e limites

Este guia adapta os conceitos e exercícios da primeira aula. As páginas referem-se à sequência física do PDF. Objetivos, práticas guiadas, aplicações industriais, cautelas estatísticas e roteiro de revisão são complementos identificados. Não substitui os slides ou a avaliação do professor e não representa uma formação completa em Big Data ou Machine Learning.

Vocabulário dos exemplos

AOI: inspeção óptica automatizada. SPI: inspeção da pasta de solda. SMT: tecnologia de montagem em superfície. ERP: sistema integrado de gestão. PCBA: placa de circuito impresso montada. Pickup: retirada de componente; feeder: alimentador; nozzle: bico de coleta. São exemplos do setor eletrônico, não dados de uma empresa.

Mapa de estudo

01. Da pergunta à decisão | 18-19; 23-24

02. Onde os dados nascem | 13-16

03. Big Data, mineração e aprendizado | 17; 21-24; 26; 30

04. Profissionais e ferramentas | 20; 32-33

05. KDD: seleção | 25-27

06. KDD: pré-processamento | 28; 43

07. KDD: transformação | 29; 43; 59

08. KDD: mineração e avaliação | 30-31

09. Pandas: ler a tabela | 35-41

10. Pandas: filtrar e agrupar | 42-44; 49-58

11. Laboratório 1: temperatura e defeitos | 45-60

12. Laboratório 2: produção e energia | 61-62

13. Transferir para a sua rotina | Complemento aplicado

14. Como revisar esta aula | Roteiro sugerido

Da pergunta à decisão

Base: páginas 18-19 e 23-24. A aplicação em AOI e a prática guiada são complementos didáticos.

Objetivo

Distinguir dado, informação e conhecimento e formular uma pergunta que apoie uma decisão.

Ciência de dados começa com uma pergunta útil.

Dados são registros. Informação é um dado colocado em contexto. Conhecimento é uma interpretação sustentada por evidências. Decisão é a ação que você toma e depois avalia. Data Science combina domínio do processo, estatística e programação. Um gráfico bonito sozinho não fecha esse ciclo.

Uma pergunta que cabe nos dados

Troque um objetivo amplo, como melhorar a qualidade, por uma pergunta delimitada: em qual produto e período o retrabalho confirmado aumentou? Defina o que será contado e qual decisão a resposta pode orientar. Sem período e denominador, duas contagens podem representar situações diferentes.

Evidência antes de intervenção

A descrição mostra o que foi observado. Uma hipótese propõe uma explicação que ainda precisa ser investigada. Registre alternativas e compare o resultado após uma intervenção; encontrar um padrão sozinho não valida a ação.

Conexão com a indústria

Na AOI (inspeção óptica automatizada): "35 apontamentos" é um dado. "35 em 1.000 placas, concentrados no componente X" é informação. Confirmar se são defeitos reais e investigar o processo gera conhecimento. Ajustar uma condição e medir o resultado fecha a decisão. Exemplo complementar, não retirado do slide.

Prática guiada - tente antes de conferir

1. Escolha um indicador do seu processo e escreva um registro bruto.

2. Acrescente período, produto e denominador para dar contexto.

3. Escreva uma hipótese e uma ação que só faria depois de investigá-la.

Pergunta de revisão

Por que começar por "vou usar IA" pode atrapalhar?

Resultado esperado

Uma resposta deve separar observação, hipótese e decisão. No exemplo AOI, 35 apontamentos não são automaticamente 35 defeitos confirmados.

Porque ainda faltam problema, métrica, dados e critério de sucesso. Comece por "quero reduzir retrabalho confirmado por lote", por exemplo.

Sua explicação: _____

Onde os dados nascem

Base: páginas 13-16. SPI, AOI, SMT, ERP, integração e tipos de estrutura são aplicações complementares.

Objetivo

Identificar fontes industriais e explicar como vincular registros sem misturar observações.

Sua fábrica já produz dados; falta conectá-los com contexto.

Fontes incluem sensores, máquinas, produção, manutenção, qualidade, energia e sistemas de gestão. Dados estruturados têm campos definidos, como uma tabela; semiestruturados têm organização flexível, como JSON; não estruturados incluem imagens e textos livres. Para integrar fontes, preserve data/hora, máquina, produto, lote e unidade.

O que cada fonte registra

Um sensor registra uma grandeza; o sistema de manutenção registra intervenções; o sistema de gestão registra ordens. Esses registros podem ter frequências e níveis diferentes. Uma imagem de inspeção e uma linha da produção não se tornam comparáveis apenas porque foram coletadas no mesmo dia.

Identificador e significado

Defina o que representa cada linha, o identificador e o horário de coleta. Anote unidade, origem e regra de medição. Para vincular tabelas, verifique se cada identificador aparece uma ou várias vezes: uma junção inadequada pode multiplicar linhas e inflar contagens.

Conexão com a indústria

SPI (inspeção da pasta de solda): volume de pasta por pad. AOI (inspeção óptica automatizada): imagem e classificação. SMT (montagem em superfície): rejeições de pickup. Seletiva: alarmes e parâmetros. ERP (sistema integrado de gestão): ordem e quantidade. Uma ligação por lote e horário permite investigar relações; juntar só pelo dia pode misturar processos diferentes.

Prática guiada - tente antes de conferir

1. Liste uma fonte de sensor, uma de qualidade e uma de manutenção.

2. Para cada fonte, registre unidade de análise, identificador, horário e unidade da medida.

3. Explique o risco de juntar registros somente pela data.

Pergunta de revisão

Qual problema ocorre ao juntar AOI e SPI sem identificar a placa?

Resultado esperado

O mapa deve permitir relacionar eventos compatíveis e revelar quando falta um identificador. Exemplo: várias inspeções da mesma placa exigem também etapa ou instante, além do ID da placa.

Você pode associar medições de placas diferentes e descobrir um padrão que não existe. A identidade e o instante de coleta fazem parte da qualidade do dado.

Sua explicação: _____

Big Data, mineração e aprendizado

Base: páginas 17, 21-24, 26 e 30. Cinco Vs, distinções operacionais e prática são complementos; não há laboratório de Big Data distribuído ou treinamento de ML nesta Aula 01.

Objetivo

Diferenciar ciência de dados, mineração, aprendizado de máquina e desafios de Big Data.

São conceitos relacionados, com papéis diferentes.

Data Science é o trabalho amplo de formular, analisar e avaliar. Data Mining busca padrões nos dados e é uma etapa do KDD. Machine Learning ajusta modelos a exemplos para generalizar a novos casos. Big Data trata desafios de escala, velocidade e diversidade; como complemento didático, os cinco Vs são volume, velocidade, variedade, veracidade e valor. Uma planilha pequena pode gerar um excelente estudo sem ser Big Data.

Do problema ao método

Estatística descreve e ajuda a avaliar evidências. Mineração procura padrões; aprendizado de máquina ajusta modelos com dados. Essas atividades podem participar do mesmo projeto. KDD descreve o processo de descoberta, incluindo preparação e avaliação, e não apenas o algoritmo.

Escolher pela tarefa

Prever uma categoria é classificação; prever um valor numérico é regressão; reunir exemplos semelhantes sem uma resposta rotulada é agrupamento. Antes de escolher um método, descreva qual saída você precisa. Cinco registros permitem explorar operações, mas não validar um sistema industrial de previsão.

Conexão com a indústria

Classificação: prever categoria de defeito. Regressão: estimar consumo. Agrupamento: reunir perfis de máquina semelhantes sem rótulos. Associação: investigar eventos que aparecem juntos. Nenhuma dessas tarefas dispensa validação.

Prática guiada - tente antes de conferir

1. Classifique as tarefas: prever defeito, estimar energia e reunir máquinas semelhantes.

2. Explique onde a limpeza de dados entra no KDD.

3. Diga por que muitos dados e um bom modelo são questões diferentes.

Pergunta de revisão

O exercício com cinco registros de produção exige uma plataforma de Big Data?

Resultado esperado

As tarefas são classificação, regressão e agrupamento. Preparação vem antes da mineração. Volume não garante qualidade, representatividade ou uma pergunta útil.

Não. Pandas e raciocínio estatístico já permitem estudar esse conjunto pequeno. A ferramenta deve acompanhar o problema e a escala.

Sua explicação: _____

Profissionais e ferramentas

Base: páginas 20 e 32-33. Distribuição de responsabilidades e orientação de execução são complementos.

Objetivo

Relacionar responsabilidades e ferramentas ao trabalho necessário no projeto.

Entenda o papel antes de escolher a biblioteca.

Engenharia de dados organiza coleta, integração e disponibilidade. Análise de dados investiga indicadores e comunica resultados. Ciência de dados desenvolve e avalia análises e modelos. Na prática há sobreposição. Python é a linguagem; Jupyter é um ambiente de exploração; Pandas trabalha com tabelas; NumPy com arrays; Matplotlib, Seaborn e Plotly com visualização; scikit-learn com aprendizado de máquina.

Responsabilidade compartilhada

Quem conhece o processo ajuda a definir o significado da medida. Quem integra os dados garante rastreabilidade. Quem analisa precisa conferir a qualidade, comunicar limites e avaliar resultados. As funções se sobrepõem; o título profissional não substitui essas responsabilidades.

Um ambiente para começar

Python executa o código, Pandas organiza tabelas e Jupyter apresenta células de texto e código. No notebook, execute a preparação antes das análises. Matplotlib, Seaborn e Plotly são opções de visualização; não é preciso instalar todas para os exercícios desta aula.

Conexão com a indústria

Para começar nesta aula: Python + Pandas. Depois, um gráfico de dispersão pode apoiar a interpretação. Você não precisa dominar todas as bibliotecas do slide para resolver os exercícios.

Prática guiada - tente antes de conferir

1. Atribua responsáveis para coleta, definição do defeito e interpretação.

2. Abra o notebook em Jupyter ou Colab e localize a preparação.

3. Explique a diferença entre linguagem, biblioteca e ambiente.

Pergunta de revisão

Quem garante que o dado da máquina chegue confiável à análise?

Resultado esperado

Python é linguagem, Pandas é biblioteca e Jupyter é ambiente. A definição de defeito depende de quem conhece e valida o processo.

A engenharia de dados tem um papel central, em parceria com produção, manutenção e qualidade. O cientista não deve assumir que o registro recebido já está correto.

Sua explicação: _____

KDD: seleção

Base: páginas 25-27; aplicação à tabela da página 45. Campos adicionais e critérios de seleção são complementos.

Objetivo

Delimitar a população e selecionar registros representativos da pergunta.

Escolha os registros que respondem à pergunta.

KDD significa descoberta de conhecimento em bases de dados. A sequência da aula é seleção, pré-processamento, transformação, mineração e interpretação/avaliação. É iterativa: um problema na avaliação pode exigir voltar ao início. Na seleção, defina período, população, campos e unidade de análise.

Defina a unidade de análise

A tabela do exercício tem cinco registros com categorias de produto, não cinco máquinas identificadas. O slide não informa lote, horário ou identidade de motor. Não atribua essas informações às linhas. Em um estudo real, defina explicitamente se cada registro é uma peça, lote ou turno.

Seleção também é uma escolha

Excluir períodos estáveis ou casos sem defeito muda a população observada. Registre critérios de inclusão e exclusão e avalie se a seleção responde à pergunta. SQL e NoSQL organizam dados de maneiras diferentes; nenhuma tecnologia é sinônimo de dado bom ou ruim.

Conexão com a indústria

Pergunta: "a temperatura se associa à taxa de defeitos?" Selecione temperatura, produção, defeitos, produto, máquina, lote e horário. Defina se cada linha representa lote, turno ou placa; não misture níveis sem critério. Máquina, lote e horário são sugestões para ampliar a coleta; não constam na tabela do exercício.

Prática guiada - tente antes de conferir

1. Escreva população, período e unidade de análise de um estudo proposto.
2. Liste os quatro campos disponíveis no exercício da página 45.
3. Separe os campos existentes daqueles que precisariam ser coletados.

Pergunta de revisão

Posso selecionar apenas lotes que deram defeito?

Resultado esperado

O exercício tem produto, produção, defeitos e temperatura. Máquina, lote e horário são campos adicionais sugeridos e não estão na tabela original.

Isso exclui os casos sem defeito e distorce a comparação. Inclua registros representativos da população que você deseja estudar.

Sua explicação: _____

KDD: pré-processamento

Base: página 28 e comandos da página 43. A separação entre estrutura e validade esclarece uma ambiguidade do slide; a simulação é complementar.

Objetivo

Diagnosticar ausências, duplicatas e tipos antes de escolher uma estratégia de limpeza.

Limpar é investigar o significado do erro.

Verifique ausências, duplicatas, tipos, unidades e valores impossíveis. NaN geralmente representa ausência em dados numéricos; zero pode ser uma medição válida. Um valor extremo pode ser falha de registro ou evento real. Dados não estruturados não são inválidos por serem imagens ou textos. Não preencha tudo com zero nem exclua linhas sem entender o motivo.

Diagnóstico não é exclusão automática

isna() identifica ausências; dropna() exclui linhas ou colunas conforme os argumentos; fillna() preenche valores. A escolha depende da causa e da finalidade. Inspecione uma cópia para experimentar e preserve os registros originais. Uma linha repetida pode representar repetição real, e não necessariamente erro.

Limpeza e estrutura são questões diferentes

Uma imagem pode ser válida e precisar de um método próprio de preparação. Um valor numérico pode estar errado mesmo em uma tabela bem estruturada. Verifique o significado de cada campo e registre o que foi alterado, em vez de tratar dados não estruturados como inválidos.

Conexão com a indústria

Uma temperatura vazia após manutenção pode indicar sensor desconectado. Trocar por zero inventa uma temperatura. Registre a ausência, investigue sua causa e escolha uma estratégia conforme o objetivo.

Prática guiada - tente antes de conferir

1. Execute a preparação do notebook e conte ausências e linhas duplicadas.

2. Em uma cópia, substitua uma temperatura por uma ausência e compare isna() e dropna().

3. Explique por que preencher a ausência com zero muda o significado da medida.

Execute os comandos e confira as saídas no notebook Aula01_Laboratorio.ipynb. Prepare df e m primeiro. O notebook traz as soluções e uma operação por célula.

Pergunta de revisão

Por que apagar toda linha com valor ausente pode gerar viés?

Resultado esperado

A tabela original tem zero ausências e zero linhas inteiramente duplicadas. A cópia com uma ausência deve ter quatro linhas após dropna(). A simulação não altera os dados originais.

Se a ausência ocorre mais em situações de falha, você remove justamente os casos importantes. Compare o padrão das ausências antes de decidir.

Sua explicação: _____

KDD: transformação

Base: página 29; criação de coluna na página 59 e comandos na página 43. Interpretação do denominador é complemento didático.

Objetivo

Criar um indicador com denominador e unidade explícitos, sem perder os dados originais.

Prepare as variáveis para a comparação e o método.

Transformar pode significar converter tipos, padronizar unidades, codificar categorias, agregar períodos ou criar indicadores. Normalização reescala valores e pode ajudar alguns algoritmos; não é uma obrigação para toda análise. Não confunda transformação com descoberta de padrões.

Conte a mesma coisa nos dois lados

Dividir ocorrências de defeito por peças produzidas calcula ocorrências por peça; multiplicar por 100 muda a escala. Se a produção for zero, a taxa não estará definida. No conjunto desta aula todos os denominadores são positivos; em dados reais, investigue zeros e ausências antes de dividir.

Transformação não cria informação ausente

rename() muda nomes e astype() converte tipos quando os valores são compatíveis. Reescalar uma temperatura não informa sua unidade e não corrige uma medição ruim. Preserve as colunas originais e descreva a fórmula do indicador derivado.

Conexão com a indústria

Comparar 12 defeitos em 120 peças com 5 em 100 exige uma taxa. Se "defeitos" conta ocorrências e uma peça pode ter vários, o resultado é ocorrências por 100 peças, não percentual de peças defeituosas. A aula não esclarece essa definição.

Prática guiada - tente antes de conferir

1. Calcule ocorrências por 100 peças para as cinco linhas.

2. Compare 12/120 com 5/100.

3. Escreva qual definição permitiria chamar a taxa de percentual de peças defeituosas.

Execute os comandos e confira as saídas no notebook Aula01_Laboratorio.ipynb. Prepare df e m primeiro. O notebook traz as soluções e uma operação por célula.

Pergunta de revisão

Qual é a taxa de 12 em 120?

Resultado esperado

As taxas são 5; 10; 5,4545; 3,3333; 11,5385 por 100 peças. Percentual de peças defeituosas exige contar cada peça no máximo uma vez.

10 por 100 peças. Só chame de 10% de peças defeituosas se cada peça for contada no máximo uma vez.

Sua explicação: _____

KDD: mineração e avaliação

Base: páginas 30-31. Separação de treino, cuidado temporal e avaliação de alertas são aprofundamentos complementares.

Objetivo

Avaliar a utilidade e os limites de um padrão antes de orientar uma ação.

Padrão encontrado não é conclusão pronta.

A mineração pode usar correlação, classificação, agrupamento e outros métodos. A avaliação pergunta se o padrão é consistente, útil e válido no contexto. Para modelos preditivos, separar dados de treino e avaliação ajuda a evitar resultados otimistas; séries temporais exigem cuidado com a ordem do tempo. Esses cuidados são aprofundamentos didáticos.

Explorar e prever têm avaliações diferentes

Uma análise exploratória descreve a amostra. Um modelo de previsão precisa ser avaliado em dados que não foram usados para ajustá-lo. Informações do futuro não devem entrar na previsão do passado. Esses cuidados não são demonstrados como treinamento de modelo no laboratório desta aula.

Traduzir o resultado em uma decisão

Pergunte se o padrão faz sentido, se permanece em outras condições e se melhora uma decisão concreta. Para um alerta, avalie quantas falhas foram detectadas, com que antecedência e quantos alertas não se confirmaram. O custo de intervir também faz parte da utilidade operacional.

Conexão com a indústria

Um alerta de parada deve ser avaliado por antecipação, falhas detectadas e falsos alarmes. Um modelo que dispara o tempo todo pode detectar falhas e ainda ser inútil na operação.

Prática guiada - tente antes de conferir

1. Escreva uma observação que poderia ser descoberta em uma tabela.

2. Proponha duas explicações alternativas para o padrão.

3. Defina uma próxima coleta e um critério para avaliar utilidade.

Pergunta de revisão

O que fazer após encontrar uma correlação forte?

Resultado esperado

Uma conclusão adequada reconhece limites e propõe um teste. Uma correlação forte por si só não demonstra causa nem valida um modelo de manutenção preditiva.

Investigar variáveis alternativas, verificar a qualidade do registro, coletar mais dados e avaliar a hipótese. Não alterar processo apenas pelo coeficiente.

Sua explicação: _____

Pandas: ler a tabela

Base: páginas 35-41, com dados da página 45. Exibição explícita dos resultados e observações de execução são adaptações pedagógicas.

Objetivo

Criar e inspecionar um DataFrame e distinguir tabela, Series e índice.

DataFrame organiza uma tabela; Series organiza uma dimensão com rótulos.

Cada linha é uma observação e cada coluna é uma variável. O índice rotula linhas e não precisa ser um ID de negócio. df.shape é atributo, sem parênteses. head() mostra linhas; info() apresenta estrutura e retorna None; describe() resume valores numéricos por padrão. import pandas as pd cria o apelido pd.

Prepare a tabela antes de consultar

pd.DataFrame() constrói a tabela de listas com o mesmo comprimento. pd.read_csv() lê texto tabular e pd.read_excel() lê planilhas; leitura de Excel e Parquet pode exigir dependências adicionais. No laboratório usamos os valores do slide para evitar depender de arquivos externos.

Ler estrutura e resumo

Uma Series é uma estrutura unidimensional com rótulos e pode existir fora de um DataFrame. head() e tail() mostram primeiras e últimas linhas; shape informa dimensões. info() imprime tipos e contagens. describe() resume colunas numéricas; selecione produto e use value_counts() para resumir a categoria.

Conexão com a indústria

Na tabela da aula, produto é categoria; produção e defeitos são contagens; temperatura é medida numérica. A unidade da temperatura não aparece explícita na tabela; confirme antes de documentar um processo real.

Prática guiada - tente antes de conferir

1. Execute a preparação e confira df.shape antes de criar novas colunas.

2. Compare o tipo e as dimensões de df["temperatura"] e df[["temperatura"]].

3. Inspecione head(), tail(), info() e describe(); descreva um resultado.

Execute os comandos e confira as saídas no notebook Aula01_Laboratorio.ipynb. Prepare df e m primeiro. O notebook traz as soluções e uma operação por célula.

Pergunta de revisão

Qual diferença entre um e dois pares de colchetes?

Resultado esperado

A tabela inicial tem shape (5, 4). A seleção simples produz Series; a seleção com lista produz DataFrame (5, 1). Após criar taxa_defeitos a tabela passa a ter cinco colunas.

df["temperatura"] retorna Series; df[["temperatura"]] retorna DataFrame com uma coluna.

Sua explicação: _____

Pandas: filtrar e agrupar

Base: páginas 42-44 e 49-58. Máscaras combinadas e interpretação dos grupos são adaptações; não são evidência causal.

Objetivo

Filtrar, ordenar e agrupar sem confundir seleção com mudança na tabela original.

Cada comando responde a uma pergunta concreta.

Um filtro produz uma máscara booleana. Use & para combinar condições e coloque cada condição entre parênteses. sort_values organiza linhas. groupby reúne categorias para calcular medidas. mean é média; median é mediana; std mede dispersão. A média sozinha pode esconder diferenças entre produtos.

Da condição à máscara

A comparação de uma coluna com um limite produz verdadeiro ou falso para cada linha. O filtro usa essa máscara. Combinações exigem & ou | e parênteses por condição. sort_values() retorna outra ordenação; sem atribuir o resultado, a tabela original permanece na ordem anterior.

O que a média esconde

groupby() calcula medidas dentro de cada categoria. Neste conjunto há dois registros de A, dois de B e apenas um de C. median() é a mediana; std() usa desvio padrão amostral por padrão. Um grupo com um único registro não fornece esse desvio; NaN nesse resultado não significa sensor ausente.

Conexão com a indústria

Temperatura > 75 seleciona as duas linhas de Motor B. Isso já acende uma dúvida: a temperatura e o tipo de motor estão associados neste conjunto. Não há amostra suficiente para separar bem os efeitos.

Prática guiada - tente antes de conferir

1. Filtre temperatura > 75 e depois combine com defeitos > 10.

2. Ordene por temperatura e confira os extremos.

3. Calcule produção média e número de registros por produto.

Execute os comandos e confira as saídas no notebook Aula01_Laboratorio.ipynb. Prepare df e m primeiro. O notebook traz as soluções e uma operação por célula.

Pergunta de revisão

Qual a média de produção do Motor A?

Resultado esperado

Os dois filtros retornam as duas linhas de B. A maior temperatura é 85 e a menor 68. Médias: A 105, B 125, C 90; contagens: A 2, B 2, C 1.

(100 + 110) / 2 = 105. Motor B = 125; Motor C = 90.

Sua explicação: _____

Laboratório 1: temperatura e defeitos

Base: páginas 45-60. As duas correlações foram recalculadas; limitações e próximos estudos são complementos didáticos.

Objetivo

Reproduzir o exercício e escrever uma conclusão que respeite o tamanho da amostra.

Há associação forte nesses cinco registros; a causa continua aberta.

Com os dados transcritos do slide: temperatura média 75,6; produção média 110; temperatura mínima 68 e máxima 85; defeitos médios 8,2. A correlação de Pearson entre temperatura e contagem de defeitos é 0.995051. Ela mede associação linear e não demonstra causalidade. Cinco registros são insuficientes para uma conclusão industrial robusta.

Contagem e taxa respondem a perguntas distintas

Temperatura versus contagem de defeitos tem Pearson 0,995051. Temperatura versus ocorrências por 100 peças tem Pearson 0,994900. A taxa leva a produção em conta, mas não elimina diferenças entre produtos nem demonstra causa. Calcule as duas medidas e indique qual está interpretando.

O alcance dos cinco registros

Há três categorias de produto e poucos registros em cada uma. Uma correlação calculada por produto teria informação insuficiente para generalizar. Não crie uma regra de operação ou um limite seguro de temperatura com base nessa tabela; proponha uma investigação mais representativa.

Conexão com a indústria

Motor B concentra as maiores temperaturas e contagens. Produto e volume produzido podem explicar parte da relação. Como próximo estudo, compare taxas dentro do mesmo produto, amplie o período e controle máquina, lote e condições de medição.

Prática guiada - tente antes de conferir

1. Reproduza visualização, seleção, filtro, médias, extremos, ordenação e agrupamento do exercício.

2. Crie taxa_defeitos e calcule correlação usando apenas as colunas numéricas selecionadas.

3. Escreva uma observação, uma limitação e uma próxima investigação.

Execute os comandos e confira as saídas no notebook Aula01_Laboratorio.ipynb. Prepare df e m primeiro. O notebook traz as soluções e uma operação por célula.

Pergunta de revisão

Qual frase é defensável: "temperatura causa defeitos" ou "nesta amostra variam juntas"?

Resultado esperado

Médias: temperatura 75,6, produção 110, defeitos 8,2. Extremos: 68 e 85. Correlações arredondadas: contagem 0,995051; taxa 0,994900. A conclusão deve descrever associação nesta amostra, sem afirmar causalidade.

Nesta amostra variam juntas. Para sustentar causalidade, precisamos de um desenho de investigação adequado e controle das explicações alternativas.

Sua explicação: _____

Laboratório 2: produção e energia

Base: páginas 61-62. A-E são máquinas, com medidas por turno. Comparabilidade e consumo específico são complementos.

Objetivo

Responder às sete questões e justificar a comparação por peças/kWh.

Maior produção e melhor eficiência são perguntas diferentes.

Dados por máquina, medidos por turno: A = 1250 peças / 420 kWh; B = 1380 / 465; C = 1190 / 390; D = 1450 / 510; E = 1320 / 405. A razão produção/energia tem unidade peças/kWh. Considere produto, período e condições equivalentes para comparar máquinas na operação real.

A unidade da razão

Produção é medida em peças por turno e energia em kWh por turno. Ao dividir, a unidade é peças/kWh. Inverter a divisão produz kWh/peça, em que valores menores indicam menor consumo específico. Indique a fórmula antes de comparar rankings.

Uma métrica não descreve toda a operação

A tabela não identifica produto, tempo efetivo de operação ou qualidade das peças. O ranking calculado é válido para os números do exercício. Comparar desempenho real exige condições equivalentes; maior razão não basta para afirmar superioridade em todos os aspectos.

Conexão com a indústria

D produz mais: 1450 peças. C consome menos: 390 kWh. Produção média: 1318 peças/turno. Energia média: 438 kWh/turno. Ordem de produção: D, B, E, A, C. Eficiências: A 2,9762; B 2,9677; C 3,0513; D 2,8431; E 3,2593 peças/kWh. E é a melhor por essa métrica.

Prática guiada - tente antes de conferir

1. Responda às questões a-e da página 62 sem abrir as respostas.

2. Calcule eficiência para A-E e ordene da maior para a menor.

3. Explique por que D lidera produção, mas E lidera peças/kWh.

Execute os comandos e confira as saídas no notebook Aula01_Laboratorio.ipynb. Prepare df e m primeiro. O notebook traz as soluções e uma operação por célula.

Pergunta de revisão

Por que escolher D como mais eficiente seria um erro?

Resultado esperado

Maior produção D; menor energia C; médias 1.318 peças/turno e 438 kWh/turno; produção D, B, E, A, C. Eficiência E, C, A, B, D; E = 3,2593 peças/kWh.

D tem maior produção absoluta, mas gasta mais energia por peça que E. A métrica precisa combinar o resultado e o recurso consumido.

Sua explicação: _____

Transferir para a sua rotina

Módulo complementar criado para aplicar o conteúdo da Aula 01. Não corresponde a um exercício ou dado de empresa presente no PDF.

Objetivo

Esboçar um projeto pequeno com dados rastreáveis e uma hipótese verificável.

Transforme experiência industrial em perguntas verificáveis.

Escolha um problema pequeno. Defina indicador, unidade, período e critério de sucesso. Monte um dicionário de dados e registre a origem. Faça análise exploratória antes de tentar prever. Escreva conclusão separando observação, hipótese e próximo teste.

Defina o entregável

Escreva problema, população, período, unidade de análise, indicador e critério de sucesso. O dicionário deve explicar nome, significado, unidade, origem e tratamento de ausências de cada campo. Se ainda não há dados, descreva a coleta necessária antes de prometer uma previsão.

Uma investigação revisável

Separe observações dos dados de possíveis explicações. Guarde versões da tabela e registre transformações para outra pessoa reproduzir a análise. Em uma comparação antes/depois, registre também mudanças de produto, máquina e setup que possam explicar o resultado.

Conexão com a indústria

Projeto: investigar rejeições de pickup (retirada de componentes). Campos sugeridos: máquina, programa, componente, feeder (alimentador), nozzle (bico de coleta), lote, horário, tentativas e rejeições. Indicador: rejeições/tentativas. Controle mudanças de setup e não use nome do operador como explicação automática de falha. Todos esses campos são sugestões, não dados da empresa.

Prática guiada - tente antes de conferir

1. Escreva um problema e uma decisão que a análise ajudaria.

2. Monte um dicionário de cinco campos com unidades e origem.

3. Defina uma hipótese e um teste, indicando o que ainda precisa coletar.

Pergunta de revisão

Qual seria seu primeiro entregável?

Resultado esperado

O esboço deve ser reproduzível, ter um indicador definido e reconhecer dados faltantes. Uma hipótese plausível continua sendo hipótese até ser avaliada.

Uma tabela confiável, um dicionário de campos, uma análise descritiva e uma hipótese testável. Um modelo de IA pode vir depois, se houver necessidade e dados adequados.

Sua explicação: _____

Como revisar esta aula

Roteiro complementar de estudo. Os tempos são estimativas para as atividades do campus, não horários ou critérios de avaliação do professor.

Objetivo

Revisar conceitos e executar os exercícios antes de marcar a própria compreensão.

Aprender é conseguir explicar e fazer sem olhar.

Sessão 1, cerca de 38 min: módulos 1 a 4, explique os conceitos em voz alta. Sessão 2, cerca de 40 min: módulos 5 a 8, aplique o KDD a um caso. Sessão 3, cerca de 71 min: módulos 9 a 12, execute o notebook e tente os exercícios antes do gabarito; divida em duas sessões se necessário. Sessão 4, cerca de 23 min: módulos 13 e 14, esboce um projeto e revise. Os tempos incluem leitura e atividades. Revise após 1, 3 e 7 dias; os intervalos são uma sugestão.

Tempo para fazer, não só para ler

Os tempos sugeridos incluem leitura, inspeção das figuras, tentativa da prática e execução no notebook. Não representam duração de áudio ou tempo cronometrado. Retome a preparação ao reiniciar o ambiente Python e compare seu raciocínio com os resultados esperados.

Autoavaliação com evidência

Explique um conceito sem consultar, execute um comando e interprete seu resultado. Se conseguir repetir o código mas não explicar a saída, retome o módulo. A marcação de compreensão é pessoal; não é uma avaliação aplicada pelo professor nem certificação do campus.

Conexão com a indústria

Em cada revisão: escreva três coisas que lembra, uma dúvida e uma situação da fábrica em que o conceito ajudaria. Volte ao módulo quando não conseguir explicar com palavras próprias.

Prática guiada - tente antes de conferir

1. Explique KDD e a diferença entre DataFrame e Series sem olhar.

2. Refaça um filtro e uma razão de eficiência no notebook.

3. Registre uma dúvida e um novo exemplo antes de consultar as respostas.

Pergunta de revisão

Quando marcar um módulo como compreendido?

Resultado esperado

Compreensão envolve explicar, executar e interpretar. Os intervalos de 1, 3 e 7 dias são uma sugestão de organização e podem ser adaptados.

Quando você consegue explicar a ideia, resolver a pergunta e dar um exemplo novo sem consultar. O checkbox serve para autoavaliação, não certifica domínio.

Sua explicação: _____

Fontes de conferência

PDF original: Aula 01, Data Science e Big Data na Indústria, Prof. Me Daniel Vieira. Pandas: pandas.pydata.org/docs/reference/api/pandas.Series.html e pandas.pydata.org/docs/reference/api/pandas.DataFrame.corr.html. KDD: Fayyad, Piatetsky-Shapiro e Smyth, Knowledge Discovery and Data Mining: Towards a Unifying Framework, 1996 (AAAI).