Aula 01 | Caderno de estudo

Data Science e Big Data na Indústria

Preparado para Carlos Pereira • Estudo guiado com aplicações à manufatura eletrônica.

Como usar

Leia a ideia central, explique com suas palavras e tente a pergunta antes de consultar a resposta. No painel interativo, use os módulos, cartões de revisão e laboratórios; no notebook, execute os comandos e altere os dados para experimentar.

Origem e limites

Base: Aula 01, Prof. Me Daniel Vieira, PDF enviado de 63 páginas. As referências de página apontam para a sequência física do arquivo. Exemplos de PCBA, cautelas estatísticas, cinco Vs e roteiro de revisão são complementos didáticos. Este material não substitui os slides ou as orientações do professor.

Mapa da aula

01. Da pergunta à decisão | páginas 13–19

02. Onde os dados nascem | páginas 13–16

03. Big Data, mineração e aprendizado | páginas 9–24

04. Profissionais e ferramentas | páginas 20; 32–33

05. KDD: seleção | páginas 25–27

06. KDD: pré-processamento | páginas 28

07. KDD: transformação | páginas 29

08. KDD: mineração e avaliação | páginas 30–31

09. Pandas: ler a tabela | páginas 35–41

10. Pandas: filtrar e agrupar | páginas 42; 49–58

11. Laboratório 1: temperatura e defeitos | páginas 45–60

12. Laboratório 2: produção e energia | páginas 61–62

13. Transferir para a sua rotina | páginas Complemento aplicado

14. Como revisar esta aula | páginas Roteiro sugerido

01 | Da pergunta à decisão

Referência no PDF: 13–19

Ciência de dados começa com uma pergunta útil.

Dados são registros. Informação é um dado colocado em contexto. Conhecimento é uma interpretação sustentada por evidências. Decisão é a ação que você toma e depois avalia. Data Science combina domínio do processo, estatística e programação. Um gráfico bonito sozinho não fecha esse ciclo.

Conexão com a prática

Na AOI: “35 apontamentos” é um dado. “35 em 1.000 placas, concentrados no componente X” é informação. Confirmar se são defeitos reais e investigar o processo gera conhecimento. Ajustar uma condição e medir o resultado fecha a decisão. Exemplo complementar, não retirado do slide.

Tente antes de consultar

Por que começar por “vou usar IA” pode atrapalhar?

Sua explicação: _____

_____

Resposta comentada

Porque ainda faltam problema, métrica, dados e critério de sucesso. Comece por “quero reduzir retrabalho confirmado por lote”, por exemplo.

02 | Onde os dados nascem

Referência no PDF: 13–16

Sua fábrica já produz dados; falta conectá-los com contexto.

Fontes incluem sensores, máquinas, produção, manutenção, qualidade, energia e sistemas de gestão. Dados estruturados têm campos definidos, como uma tabela; semiestruturados têm organização flexível, como JSON; não estruturados incluem imagens e textos livres. Para integrar fontes, preserve data/hora, máquina, produto, lote e unidade.

Conexão com a prática

SPI: volume de pasta por pad. AOI: imagem e classificação. SMT: rejeições de pickup. Seletiva: alarmes e parâmetros. ERP: ordem e quantidade. Uma ligação por lote e horário permite investigar relações; juntar só pelo dia pode misturar processos diferentes.

Tente antes de consultar

Qual problema ocorre ao juntar AOI e SPI sem identificar a placa?

Sua explicação: _____

_____

Resposta comentada

Você pode associar medições de placas diferentes e descobrir um padrão que não existe. A identidade e o instante de coleta fazem parte da qualidade do dado.

03 | Big Data, mineração e aprendizado

Referência no PDF: 9–24

São conceitos relacionados, com papéis diferentes.

Data Science é o trabalho amplo de formular, analisar e avaliar. Data Mining busca padrões nos dados e é uma etapa do KDD. Machine Learning ajusta modelos a exemplos para generalizar a novos casos. Big Data trata desafios de escala, velocidade e diversidade; como complemento didático, os cinco Vs são volume, velocidade, variedade, veracidade e valor. Uma planilha pequena pode gerar um excelente estudo sem ser Big Data.

Conexão com a prática

Classificação: prever categoria de defeito. Regressão: estimar consumo. Agrupamento: reunir perfis de máquina semelhantes sem rótulos. Associação: investigar eventos que aparecem juntos. Nenhuma dessas tarefas dispensa validação.

Tente antes de consultar

O exercício de cinco motores exige uma plataforma de Big Data?

Sua explicação: _____

_____

Resposta comentada

Não. Pandas e raciocínio estatístico já permitem estudar esse conjunto pequeno. A ferramenta deve acompanhar o problema e a escala.

04 | Profissionais e ferramentas

Referência no PDF: 20; 32–33

Entenda o papel antes de escolher a biblioteca.

Engenharia de dados organiza coleta, integração e disponibilidade. Análise de dados investiga indicadores e comunica resultados. Ciência de dados desenvolve e avalia análises e modelos. Na prática há sobreposição. Python é a linguagem; Jupyter é um ambiente de exploração; Pandas trabalha com tabelas; NumPy com arrays; Matplotlib, Seaborn e Plotly com visualização; scikit-learn com aprendizado de máquina.

Conexão com a prática

Para começar nesta aula: Python + Pandas. Depois, um gráfico de dispersão pode apoiar a interpretação. Você não precisa dominar todas as bibliotecas do slide para resolver os exercícios.

Tente antes de consultar

Quem garante que o dado da máquina chegue confiável à análise?

Sua explicação: _____

_____

Resposta comentada

A engenharia de dados tem um papel central, em parceria com produção, manutenção e qualidade. O cientista não deve assumir que o registro recebido já está correto.

05 | KDD: seleção

Referência no PDF: 25–27

Escolha os registros que respondem à pergunta.

KDD significa descoberta de conhecimento em bases de dados. A sequência da aula é seleção, pré-processamento, transformação, mineração e interpretação/avaliação. É iterativa: um problema na avaliação pode exigir voltar ao início. Na seleção, defina período, população, campos e unidade de análise.

Conexão com a prática

Pergunta: “a temperatura se associa à taxa de defeitos?” Selecione temperatura, produção, defeitos, produto, máquina, lote e horário. Defina se cada linha representa lote, turno ou placa; não misture níveis sem critério.

Tente antes de consultar

Posso selecionar apenas lotes que deram defeito?

Sua explicação: _____

_____

Resposta comentada

Isso exclui os casos sem defeito e distorce a comparação. Inclua registros representativos da população que você deseja estudar.

06 | KDD: pré-processamento

Referência no PDF: 28

Limpar é investigar o significado do erro.

Verifique ausências, duplicatas, tipos, unidades e valores impossíveis. NaN geralmente representa ausência em dados numéricos; zero pode ser uma medição válida. Um valor extremo pode ser falha de registro ou evento real. Dados não estruturados não são inválidos por serem imagens ou textos. Não preencha tudo com zero nem exclua linhas sem entender o motivo.

Conexão com a prática

Uma temperatura vazia após manutenção pode indicar sensor desconectado. Trocar por zero inventa uma temperatura. Registre a ausência, investigue sua causa e escolha uma estratégia conforme o objetivo.

```
df.info()
df.isna().sum()
df.duplicated().sum()
```

Tente antes de consultar

Por que apagar toda linha com valor ausente pode gerar viés?

Sua explicação: _____

_____

Resposta comentada

Se a ausência ocorre mais em situações de falha, você remove justamente os casos importantes. Compare o padrão das ausências antes de decidir.

07 | KDD: transformação

Referência no PDF: 29

Prepare as variáveis para a comparação e o método.

Transformar pode significar converter tipos, padronizar unidades, codificar categorias, agregar períodos ou criar indicadores. Normalização reescala valores e pode ajudar alguns algoritmos; não é uma obrigação para toda análise. Não confunda transformação com descoberta de padrões.

Conexão com a prática

Comparar 12 defeitos em 120 peças com 5 em 100 exige uma taxa. Se “defeitos” conta ocorrências e uma peça pode ter vários, o resultado é ocorrências por 100 peças, não percentual de peças defeituosas. A aula não esclarece essa definição.

```
df['taxa_defeitos'] = df['defeitos'] / df['producao'] * 100
```

Tente antes de consultar

Qual é a taxa de 12 em 120?

Sua explicação: _____

_____

Resposta comentada

10 por 100 peças. Só chame de 10% de peças defeituosas se cada peça for contada no máximo uma vez.

08 | KDD: mineração e avaliação

Referência no PDF: 30–31

Padrão encontrado não é conclusão pronta.

A mineração pode usar correlação, classificação, agrupamento e outros métodos. A avaliação pergunta se o padrão é consistente, útil e válido no contexto. Para modelos preditivos, separar dados de treino e avaliação ajuda a evitar resultados otimistas; séries temporais exigem cuidado com a ordem do tempo. Esses cuidados são aprofundamentos didáticos.

Conexão com a prática

Um alerta de parada deve ser avaliado por antecipação, falhas detectadas e falsos alarmes. Um modelo que dispara o tempo todo pode detectar falhas e ainda ser inútil na operação.

Tente antes de consultar

O que fazer após encontrar uma correlação forte?

Sua explicação: _____

_____

Resposta comentada

Investigar variáveis alternativas, verificar a qualidade do registro, coletar mais dados e avaliar a hipótese. Não alterar processo apenas pelo coeficiente.

09 | Pandas: ler a tabela

Referência no PDF: 35–41

DataFrame é tabela; Series é uma coluna com índice.

Cada linha é uma observação e cada coluna é uma variável. O índice rotula linhas e não precisa ser um ID de negócio. df.shape é atributo, sem parênteses. head() mostra linhas; info() apresenta estrutura e retorna None; describe() resume valores numéricos por padrão. import pandas as pd cria o apelido pd.

Conexão com a prática

Na tabela da aula, produto é categoria; produção e defeitos são contagens; temperatura é medida numérica. A unidade da temperatura não aparece explícita na tabela; confirme antes de documentar um processo real.

```
import pandas as pd
df.head()
df.shape
df.info()
df.describe()
df['temperatura']
df[['produto', 'temperatura']]
```

Tente antes de consultar

Qual diferença entre um e dois pares de colchetes?

Sua explicação: _____

_____

Resposta comentada

df["temperatura"] retorna Series; df[["temperatura"]] retorna DataFrame com uma coluna.

10 | Pandas: filtrar e agrupar

Referência no PDF: 42; 49–58

Cada comando responde a uma pergunta concreta.

Um filtro produz uma máscara booleana. Use & para combinar condições e coloque cada condição entre parênteses. sort_values organiza linhas. groupby reúne categorias para calcular medidas. mean é média; median é mediana; std mede dispersão. A média sozinha pode esconder diferenças entre produtos.

Conexão com a prática

Temperatura > 75 seleciona as duas linhas de Motor B. Isso já acende uma dúvida: a temperatura e o tipo de motor estão associados neste conjunto. Não há amostra suficiente para separar bem os efeitos.

```
df[df['temperatura'] > 75]
df[(df['temperatura'] > 75) & (df['defeitos'] > 10)]
df.sort_values('temperatura', ascending=False)
df.groupby('produto')['producao'].mean()
df.groupby('produto').agg(
    producao=('producao','mean'),
    defeitos=('defeitos','mean'))
```

Tente antes de consultar

Qual a média de produção do Motor A?

Sua explicação: _____

_____

Resposta comentada

(100 + 110) / 2 = 105. Motor B = 125; Motor C = 90.

11 | Laboratório 1: temperatura e defeitos

Referência no PDF: 45–60

Há associação forte nesses cinco registros; a causa continua aberta.

Com os dados transcritos do slide: temperatura média 75,6; produção média 110; temperatura mínima 68 e máxima 85; defeitos médios 8,2. A correlação de Pearson entre temperatura e contagem de defeitos é 0.995051. Ela mede associação linear e não demonstra causalidade. Cinco registros são insuficientes para uma conclusão industrial robusta.

Conexão com a prática

Motor B concentra as maiores temperaturas e contagens. Produto e volume produzido podem explicar parte da relação. Como próximo estudo, compare taxas dentro do mesmo produto, amplie o período e controle máquina, lote e condições de medição.

```
df[['producao', 'defeitos', 'temperatura']].corr()
df[['temperatura', 'taxa_defeitos']].corr()
```

Tente antes de consultar

Qual frase é defensável: “temperatura causa defeitos” ou “nesta amostra variam juntas”?

Sua explicação: _____

_____

Resposta comentada

Nesta amostra variam juntas. Para sustentar causalidade, precisamos de um desenho de investigação adequado e controle das explicações alternativas.

12 | Laboratório 2: produção e energia

Referência no PDF: 61–62

Maior produção e melhor eficiência são perguntas diferentes.

Dados por turno: A = 1250 peças / 420 kWh; B = 1380 / 465; C = 1190 / 390; D = 1450 / 510; E = 1320 / 405. A razão produção/energia tem unidade peças/kWh. Considere produto, período e condições equivalentes para comparar máquinas na operação real.

Conexão com a prática

D produz mais: 1450 peças. C consome menos: 390 kWh. Produção média: 1318 peças/turno. Energia média: 438 kWh/turno. Ordem de produção: D, B, E, A, C. Eficiências: A 2,9762; B 2,9677; C 3,0513; D 2,8431; E 3,2593 peças/kWh. E é a melhor por essa métrica.

```
m['eficiencia'] = m['producao'] / m['energia']
m.sort_values('eficiencia', ascending=False)
m['producao'].mean()
m['energia'].mean()
```

Tente antes de consultar

Por que escolher D como mais eficiente seria um erro?

Sua explicação: _____

_____

Resposta comentada

D tem maior produção absoluta, mas gasta mais energia por peça que E. A métrica precisa combinar o resultado e o recurso consumido.

13 | Transferir para a sua rotina

Referência no PDF: Complemento aplicado

Transforme experiência industrial em perguntas verificáveis.

Escolha um problema pequeno. Defina indicador, unidade, período e critério de sucesso. Monte um dicionário de dados e registre a origem. Faça análise exploratória antes de tentar prever. Escreva conclusão separando observação, hipótese e próximo teste.

Conexão com a prática

Projeto: investigar rejeições de pickup. Campos sugeridos: máquina, programa, componente, feeder, nozzle, lote, horário, tentativas e rejeições. Indicador: rejeições/tentativas. Controle mudanças de setup e não use nome do operador como explicação automática de falha. Todos esses campos são sugestões, não dados da empresa.

Tente antes de consultar

Qual seria seu primeiro entregável?

Sua explicação: _____

_____

Resposta comentada

Uma tabela confiável, um dicionário de campos, uma análise descritiva e uma hipótese testável. Um modelo de IA pode vir depois, se houver necessidade e dados adequados.

14 | Como revisar esta aula

Referência no PDF: Roteiro sugerido

Aprender é conseguir explicar e fazer sem olhar.

Sessão 1, 30 min: módulos 1 a 4, explique os conceitos em voz alta. Sessão 2, 40 min: módulos 5 a 8, aplique o KDD a um caso. Sessão 3, 50 min: módulos 9 a 12, execute o notebook e tente os exercícios antes do gabarito. Sessão 4, 30 min: módulo 13, esboce um projeto industrial. Revise após 1, 3 e 7 dias; os intervalos são uma sugestão.

Conexão com a prática

Em cada revisão: escreva três coisas que lembra, uma dúvida e uma situação da fábrica em que o conceito ajudaria. Volte ao módulo quando não conseguir explicar com palavras próprias.

Tente antes de consultar

Quando marcar um módulo como compreendido?

Sua explicação: _____

_____

Resposta comentada

Quando você consegue explicar a ideia, resolver a pergunta e dar um exemplo novo sem consultar. O checkbox serve para autoavaliação, não certifica domínio.

Fontes para conferir

PDF-base enviado, páginas 1–63. Pandas: https://pandas.pydata.org/docs/getting_started/intro_tutorials/index.html e https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.corr.html. Consulta em 03/10/2026. A configuração do curso deve ser confirmada com o professor; o caderno prioriza os conceitos e exercícios.