# Aula 02

# Pandas e análise de dados industriais

## Caderno de estudo

14 tópicos · quatro laboratórios · projeto S&M Industry em cinco etapas

Complemento didático ao PDF da disciplina Data Science e Big Data, do Prof. Me Daniel Vieira. Explicações e práticas deste guia foram preparadas para o ambiente de estudos; não substituem os slides originais.

## Como estudar

Leia o conceito, execute o código no notebook e responda à pergunta antes de consultar a revisão. O áudio no campus tem quatro trechos por tópico: ideia central, prática industrial, pergunta e revisão.

## Bases utilizadas

producao.csv, base_p52.csv, base_p54.csv e manutencao.csv são cópias locais fornecidas pelo usuário. Os resultados se referem a essas versões. Consulte proveniencia.json para os hashes.

# Seu percurso

01 · Comece pela pergunta, termine com uma decisão — PDF 2–7

02 · Pandas: Series, DataFrame e índice — PDF 8–12

03 · Importe e conheça seus dados — PDF 13–18; 21–22

04 · Selecione colunas e filtre observações — PDF 23–26

05 · Resuma sem esconder a distribuição — PDF 27–29; 32

06 · Agrupamentos e taxas com denominador correto — PDF 30–31; 35–44

07 · Qualidade dos dados e transformações — PDF 13–17; 65; 71–72

08 · Crie indicadores e investigue associações — PDF 33–34; 51

09 · Gráficos que respondem à pergunta — PDF 37–48

10 · Laboratório: produção e qualidade por turno — PDF 35–48; 51

11 · Laboratório: eficiência energética das máquinas — PDF 49–50

12 · Laboratório: viagens, tempo e vendas — PDF 52–56

13 · Projeto S&M: exploração e preparação — PDF 57–72

14 · Projeto S&M: modelos, agrupamentos e escala — PDF 73–80

## Materiais e execução

Baixe o notebook e os quatro CSVs para a mesma pasta. Execute as células em ordem no Jupyter ou Google Colab. O navegador do campus apresenta código, mas não executa Python. Spark depende de instalação e Java compatível.

TÓPICO 01 · FUNDAMENTOS · PDF 2–7

# Comece pela pergunta, termine com uma decisão

## O que você vai aprender

Formular uma pergunta verificável com unidade, período e decisão.

## Uma análise útil conecta problema, dados e ação.

Antes de abrir o notebook, descreva o problema, a unidade de observação, o período e o indicador de sucesso. A exploração pode revelar que os dados disponíveis ainda não respondem à pergunta. Nesse caso, revise o escopo em vez de forçar uma conclusão.

## Defina a observação

Uma linha pode representar uma peça, turno, viagem ou leitura de sensor. Somar ou comparar sem entender essa unidade produz indicadores enganosos.

## Do resultado à ação

Uma associação orienta investigação. A recomendação deve indicar evidência, limitações e como verificar o efeito de uma mudança.

## Conexão com a indústria

Uma fábrica quer reduzir paradas não planejadas. Uma pergunta investigável é: em quais condições de temperatura e vibração há maior frequência de registros com falha? Isso é diferente de afirmar que um sensor prevê uma falha futura.

TÓPICO 01 · PRÁTICA E REVISÃO

# Experimente e explique

## Código de referência

```
pergunta = "Quais condições estão associadas às falhas?"
unidade = "registro de uma máquina em um instante"
print(pergunta, unidade)
```

Trecho de referência: variáveis compartilhadas são preparadas no notebook. Use o notebook para copiar e executar o código completo.

## Prática guiada

1. Escreva uma pergunta sobre seu processo.
2. Defina uma linha dos dados e a população analisada.
3. Anote uma decisão e a evidência necessária para apoiá-la.

## Resultado esperado

Uma pergunta delimitada, acompanhada de unidade, período e indicador.

## Pare e pense

Qual é a diferença entre classificar uma falha registrada e prever uma falha futura?

## Resposta comentada

Classificar usa o rótulo do registro; prever exige definir um horizonte futuro, garantir que as variáveis estejam disponíveis antes do evento e validar a separação temporal.

Base: Aula 02, páginas 2–7. Explicações, verificações e práticas guiadas são complementos didáticos; resultados usam as bases locais identificadas em Materiais.

TÓPICO 02 · PANDAS · PDF 8–12

# Pandas: Series, DataFrame e índice

## O que você vai aprender

Distinguir Series, DataFrame, coluna e índice.

## Uma tabela tem colunas, tipos e um índice; cada um tem uma função.

Pandas organiza dados tabulares. Uma Series representa uma sequência rotulada e um DataFrame reúne colunas alinhadas pelo índice. O índice não precisa ser um identificador único de equipamento. Ao combinar objetos, o alinhamento por rótulo pode mudar o resultado esperado.

## Prepare o ambiente

No terminal, pip install pandas instala o pacote. No notebook, importe pandas como pd. O campus mostra o código; a execução ocorre no notebook Jupyter ou Colab.

## Tipos afetam operações

Texto numérico não se comporta como número. Confira dtypes e converta explicitamente quando necessário, registrando valores que não puderam ser convertidos.

## Conexão com a indústria

Uma coluna de temperatura é uma Series; leituras de máquina, horário e temperatura formam um DataFrame. A máquina pode se repetir em instantes diferentes.

TÓPICO 02 · PRÁTICA E REVISÃO

# Experimente e explique

## Código de referência

```
import pandas as pd
df = pd.DataFrame({"maquina": ["M01", "M02"], "temperatura": [65, 72]})
print(type(df["temperatura"]))
print(type(df[["temperatura"]]))
```

Trecho de referência: variáveis compartilhadas são preparadas no notebook. Use o notebook para copiar e executar o código completo.

## Prática guiada

1. Crie duas colunas com duas linhas.
2. Selecione uma coluna com um e dois pares de colchetes.
3. Confira shape, columns e dtypes.

## Resultado esperado

O DataFrame tem forma (2, 2), e a seleção com colchetes duplos mantém duas dimensões.

## Pare e pense

Selecionar df["temperatura"] é igual a df[["temperatura"]]?

## Resposta comentada

Os valores podem coincidir, mas o primeiro objeto é uma Series e o segundo é um DataFrame com uma coluna. Essa diferença importa em operações e bibliotecas.

Base: Aula 02, páginas 8–12. Explicações, verificações e práticas guiadas são complementos didáticos; resultados usam as bases locais identificadas em Materiais.

TÓPICO 03 · PANDAS · PDF 13–18; 21–22

# Importe e conheça seus dados

## O que você vai aprender

Importar CSV e verificar estrutura antes de calcular indicadores.

## Ler um arquivo é o início da investigação, não sua validação.

Use read_csv para CSV e escolha o separador e a codificação conforme o arquivo. head mostra uma amostra; shape informa dimensões; info resume colunas e valores não nulos. Uma leitura sem erro não garante que datas, unidades e faltantes estejam corretos.

## Biblioteca e formatos

read_excel pode exigir um mecanismo adicional para XLSX. Parquet também requer dependências específicas. As bases desta aula estão disponíveis em CSV.

## Dicionário de dados

Registre o significado de cada coluna, sua unidade e o que uma linha representa. Não atribua graus Celsius a um exemplo que não especifica a unidade.

## Conexão com a indústria

producao.csv possui 100 registros com data, turno, produto, peças produzidas, defeituosas e aprovadas. Observe se aprovadas mais defeituosas corresponde ao total produzido.

TÓPICO 03 · PRÁTICA E REVISÃO

# Experimente e explique

## Código de referência

```
import pandas as pd
producao = pd.read_csv("producao.csv")
print(producao.shape)
print(producao.head())
producao.info()
producao["data"] = pd.to_datetime(producao["data"], errors="raise")
```

Trecho de referência: variáveis compartilhadas são preparadas no notebook. Use o notebook para copiar e executar o código completo.

## Prática guiada

1. Baixe producao.csv em Materiais.
2. Confira 100 linhas e seis colunas.
3. Valide a soma de aprovadas e defeituosas por registro.

## Resultado esperado

100 registros, seis atributos e uma verificação explícita da consistência dos totais.

## Pare e pense

Por que olhar apenas head pode esconder um problema?

## Resposta comentada

head exibe poucas linhas. Ausências, tipos inconsistentes e duplicatas podem aparecer em outra parte do arquivo. Combine amostra, info, estatísticas e verificações de integridade.

Base: Aula 02, páginas 13–18; 21–22. Explicações, verificações e práticas guiadas são complementos didáticos; resultados usam as bases locais identificadas em Materiais.

TÓPICO 04 · PANDAS · PDF 23–26

# Selecione colunas e filtre observações

## O que você vai aprender

Construir filtros e explicar o subconjunto selecionado.

## Um filtro precisa representar exatamente a população da pergunta.

Selecione colunas por nome e use máscaras booleanas para restringir linhas. loc combina rótulos de linhas e colunas; iloc usa posições. Ao combinar condições, coloque cada uma entre parênteses e use & ou |. Para alterar o recorte original, prefira uma atribuição explícita com loc.

## Rótulo ou posição

loc usa rótulos, inclusive nas colunas; iloc usa posições inteiras. Não suponha que o índice continue sequencial depois de uma filtragem.

## Condição vazia também informa

Se o filtro não retorna linhas, confira os valores e o critério antes de concluir que não há ocorrências no processo.

## Conexão com a indústria

Para investigar registros do turno Noite acima de 300 peças, combine turno e volume. O resultado descreve esse subconjunto, não toda a produção.

TÓPICO 04 · PRÁTICA E REVISÃO

# Experimente e explique

## Código de referência

```
recorte = producao.loc[
    (producao["turno"] == "Noite") &
    (producao["pecas_produzidas"] > 300),
    ["data", "turno", "pecas_produzidas"]
]
print(recorte.head())
```

Trecho de referência: variáveis compartilhadas são preparadas no notebook. Use o notebook para copiar e executar o código completo.

## Prática guiada

1. Liste os turnos com unique.
2. Filtre Noite e produção acima de 300.
3. Compare a quantidade de linhas antes e depois.

## Resultado esperado

Um recorte com as três colunas escolhidas e critérios explícitos.

## Pare e pense

O que muda entre filtrar peças acima de 300 e obter a média de todos os registros?

## Resposta comentada

O filtro altera a população e pode aumentar a média por construção. A comparação exige informar quem entrou no cálculo.

Base: Aula 02, páginas 23–26. Explicações, verificações e práticas guiadas são complementos didáticos; resultados usam as bases locais identificadas em Materiais.

TÓPICO 05 · PANDAS · PDF 27–29; 32

# Resuma sem esconder a distribuição

## O que você vai aprender

Calcular estatísticas e interpretar seus limites.

## A média é um resumo; distribuição e tamanho da amostra dão contexto.

mean, median, min, max e describe descrevem aspectos distintos de uma variável. A média é sensível a valores extremos. O desvio padrão resume dispersão e deve ter sua convenção informada. Ordenar ajuda a localizar registros extremos, mas não explica sua causa.

## Compare resumos

Média, mediana e extremos juntos ajudam a perceber assimetria. Para amostras pequenas, visualize os registros individuais.

## Ordene com objetivo

Ordenar pela temperatura permite inspecionar os maiores valores. Um ranking sozinho não demonstra relação causal com defeitos.

## Conexão com a indústria

Nos cinco registros de motores do exemplo, a temperatura média é 75,6; a menor é 68 e a maior é 85. A unidade da temperatura não está especificada nesse exemplo do material.

TÓPICO 05 · PRÁTICA E REVISÃO

# Experimente e explique

## Código de referência

```
df = pd.DataFrame({"produto": ["Motor A", "Motor B", "Motor A", "Motor C", "Motor B"],
 "producao": [100,120,110,90,130], "defeitos": [5,12,6,3,15],
 "temperatura": [70,82,73,68,85]})
print(df["temperatura"].agg(["mean", "median", "min", "max"]))
print(df.sort_values("temperatura", ascending=False))
```

Trecho de referência: variáveis compartilhadas são preparadas no notebook. Use o notebook para copiar e executar o código completo.

## Prática guiada

1. Execute a tabela de cinco motores.
2. Calcule média e mediana da temperatura.
3. Explique o que o máximo não permite concluir.

## Resultado esperado

Média 75,6, mediana 73, mínimo 68 e máximo 85.

## Pare e pense

O registro de maior temperatura é necessariamente o mais representativo?

## Resposta comentada

Não. Um extremo pode ser raro, erro de medição ou evento operacional real. É preciso investigar contexto, frequência e distribuição.

Base: Aula 02, páginas 27–29; 32. Explicações, verificações e práticas guiadas são complementos didáticos; resultados usam as bases locais identificadas em Materiais.

TÓPICO 06 · PANDAS · PDF 30–31; 35–44

# Agrupamentos e taxas com denominador correto

## O que você vai aprender

Construir uma agregação e calcular a taxa ponderada de defeitos.

## Compare grupos por volume e taxa, sempre com o denominador à vista.

groupby separa registros em grupos e agg define os resumos. Para medir a fração total de peças defeituosas por turno, divida a soma de defeituosas pela soma de produzidas. Fazer a média das porcentagens de cada linha dá peso igual a registros com volumes diferentes.

## Defina a métrica

Total produzido, média por registro e taxa de defeitos respondem a perguntas diferentes. Nomeie a unidade de cada resultado.

## Cheque o volume

Um grupo com poucos registros tem uma taxa mais instável. Mostre a contagem de observações junto à comparação.

## Conexão com a indústria

Um turno pode produzir mais e ter mais defeitos absolutos, mas uma taxa menor. O painel de laboratórios apresenta volume, defeitos e taxa por turno para a base local.

# Experimente e explique

## Código de referência

```
resumo = producao.groupby("turno").agg(
 produzidas=("pecas_produzidas", "sum"),
 defeituosas=("pecas_defeituosas", "sum"),
 media=("pecas_produzidas", "mean"))
resumo["taxa_pct"] = 100 * resumo["defeituosas"] / resumo["produzidas"]
print(resumo)
```

Trecho de referência: variáveis compartilhadas são preparadas no notebook. Use o notebook para copiar e executar o código completo.

## Prática guiada

1. Some produção e defeitos por turno.
2. Calcule a taxa com os totais agregados.
3. Compare o ranking de volume com o ranking de taxa.

## Resultado esperado

Uma tabela que distingue peças, peças por registro e percentual de defeitos.

## Pare e pense

A média simples das taxas por registro é sempre a taxa total?

## Resposta comentada

Não. A taxa total equivale à média ponderada pelo volume produzido. A média simples só coincide em condições específicas, como denominadores iguais.

Base: Aula 02, páginas 30–31; 35–44. Explicações, verificações e práticas guiadas são complementos didáticos; resultados usam as bases locais identificadas em Materiais.

TÓPICO 07 · PANDAS · PDF 13–17; 65; 71–72

# Qualidade dos dados e transformações

## O que você vai aprender

Auditar a base e documentar um tratamento justificável.

## Tratar dados exige justificar escolhas e preservar o original.

Inspecione ausências, duplicatas e tipos antes de preencher ou excluir. Um valor ausente não significa zero; um outlier não é automaticamente erro. Copie a base para análise e registre cada transformação. Quando há modelagem, aprenda imputação e escalas usando apenas o conjunto de treinamento.

## Duplicata depende da chave

Duas linhas idênticas são diferentes de duas leituras da mesma máquina em horários distintos. Verifique a unidade de observação antes de remover.

## Outliers precisam de domínio

Limites estatísticos sinalizam observações para inspeção. Uma temperatura extrema pode ser precisamente o evento relevante para manutenção.

## Conexão com a indústria

manutencao.csv contém 5.050 linhas brutas. Há registros repetidos e valores ausentes: eles fazem parte da investigação. O relatório de qualidade em Laboratórios quantifica essas situações.

TÓPICO 07 · PRÁTICA E REVISÃO

# Experimente e explique

## Código de referência

```
manutencao = pd.read_csv("manutencao.csv")
print(manutencao.isna().sum())
print("Duplicatas exatas:", manutencao.duplicated().sum())
base = manutencao.drop_duplicates().copy()
base["timestamp"] = pd.to_datetime(base["timestamp"], errors="raise")
```

Trecho de referência: variáveis compartilhadas são preparadas no notebook. Use o notebook para copiar e executar o código completo.

## Prática guiada

1. Conte ausências por coluna e duplicatas exatas.
2. Crie uma cópia sem duplicatas exatas.
3. Registre quantas linhas foram removidas e por quê.

## Resultado esperado

Um relatório antes/depois, sem alteração silenciosa do arquivo original.

## Pare e pense

Por que preencher todos os faltantes com zero pode distorcer uma análise?

## Resposta comentada

Zero pode representar uma medição real. Substituir uma ausência por zero inventa essa medição e muda médias, correlações e decisões.

Base: Aula 02, páginas 13–17; 65; 71–72. Explicações, verificações e práticas guiadas são complementos didáticos; resultados usam as bases locais identificadas em Materiais.

TÓPICO 08 · ANÁLISE · PDF 33–34; 51

# Crie indicadores e investigue associações

## O que você vai aprender

Criar uma taxa e distinguir associação de explicação causal.

## Uma variável derivada deve ter fórmula, unidade e interpretação.

A taxa de defeitos relaciona defeitos ao volume produzido. A correlação de Pearson mede associação linear e varia entre menos um e um. Ela depende do recorte, dos valores extremos e de outras variáveis. Correlação forte não estabelece causalidade nem garante capacidade de previsão fora da amostra.

## Proteja o denominador

Se a produção for zero, a taxa não está definida. Marque a condição e investigue; não transforme divisão por zero em um percentual arbitrário.

## Olhe o gráfico

A mesma correlação pode esconder formatos diferentes. Um gráfico de dispersão ajuda a detectar grupos, extremos e relações não lineares.

## Conexão com a indústria

Nos cinco motores, temperatura e quantidade de defeitos variam juntas. Compare também a taxa, porque o volume produzido difere entre registros e produtos.

TÓPICO 08 · PRÁTICA E REVISÃO

# Experimente e explique

## Código de referência

```
df["taxa_defeitos_pct"] = 100 * df["defeitos"] / df["producao"].where(df["producao"] > 0)
print(df[["temperatura", "defeitos", "taxa_defeitos_pct"]].corr())
```

Trecho de referência: variáveis compartilhadas são preparadas no notebook. Use o notebook para copiar e executar o código completo.

## Prática guiada

1. Crie a taxa no exemplo de motores.
2. Compare correlação com contagem e com taxa.
3. Escreva uma conclusão que não afirme causalidade.

## Resultado esperado

Indicador em porcentagem e interpretação limitada à associação observada.

## Pare e pense

Uma correlação alta entre produção e defeitos prova piora da qualidade?

## Resposta comentada

Não. Produzir mais pode aumentar a contagem de defeitos sem aumentar sua proporção. Analise a taxa, o produto, o turno e o período.

Base: Aula 02, páginas 33–34; 51. Explicações, verificações e práticas guiadas são complementos didáticos; resultados usam as bases locais identificadas em Materiais.

TÓPICO 09 · ANÁLISE · PDF 37–48

# Gráficos que respondem à pergunta

## O que você vai aprender

Criar uma visualização com título, eixos e unidade.

## Escolha o gráfico pela comparação que deseja fazer.

Use barras para comparar categorias, linhas para evolução temporal e dispersão para associação entre variáveis. Em Matplotlib, Figure é a figura completa e Axes é a área de desenho. Rotule unidades e fonte; não deixe cor e decoração substituírem o significado.

## Uma pergunta por gráfico

Um gráfico de volume e um de qualidade podem ficar lado a lado. Isso facilita distinguir quantidade absoluta e proporção.

## Acessibilidade

Inclua a tabela com os valores e use rótulos além de cores. Evite gráficos tridimensionais que deformam a percepção do tamanho.

## Conexão com a indústria

Barras de produção por turno mostram volume. Outra visualização mostra taxa de defeitos. Combinar ambos sem deixar as unidades claras pode induzir uma comparação errada.

TÓPICO 09 · PRÁTICA E REVISÃO

# Experimente e explique

## Código de referência

```
import matplotlib.pyplot as plt
fig, ax = plt.subplots(figsize=(8, 5))
resumo["taxa_pct"].plot.bar(ax=ax, color="#157d8b")
ax.set(xlabel="Turno", ylabel="Peças defeituosas (%)", title="Taxa por turno")
plt.tight_layout()
plt.show()
```

Trecho de referência: variáveis compartilhadas são preparadas no notebook. Use o notebook para copiar e executar o código completo.

## Prática guiada

1. Desenhe barras da taxa por turno.
2. Adicione o título e a unidade percentual.
3. Compare o resultado com a tabela agregada.

## Resultado esperado

Barras consistentes com as taxas calculadas, sem confundir volume e qualidade.

## Pare e pense

Por que ordenar datas como texto pode criar uma sequência incorreta?

## Resposta comentada

Formatos textuais podem ordenar por dia ou mês antes do ano. Converta para datetime e ordene cronologicamente antes de desenhar.

Base: Aula 02, páginas 37–48. Explicações, verificações e práticas guiadas são complementos didáticos; resultados usam as bases locais identificadas em Materiais.

TÓPICO 10 · LABORATÓRIOS · PDF 35–48; 51

# Laboratório: produção e qualidade por turno

## O que você vai aprender

Responder ao exemplo de produção com cálculos reproduzíveis.

## Um turno eficiente precisa ser avaliado por produção e qualidade.

A base local registra 100 observações de produção. Responda às perguntas do material por total de peças, maior produção por turno, média por registro e maior taxa de defeitos. Depois investigue a correlação entre volume e contagem de defeitos sem transformá-la em causalidade.

## Confira as identidades

Aprovadas mais defeituosas deve ser igual a produzidas na base fornecida. Uma inconsistência requer investigação antes de calcular taxas.

## Interprete o resultado

A análise descreve o período fornecido. Comparar turnos também pode exigir controlar produto, equipamento e condições operacionais.

## Conexão com a indústria

No laboratório interativo, alterne a métrica para ver como o ranking dos turnos muda. Confira o número de registros: os grupos não precisam ter o mesmo tamanho.

TÓPICO 10 · PRÁTICA E REVISÃO

# Experimente e explique

## Código de referência

```
print("Total:", producao["pecas_produzidas"].sum())
print(producao.groupby("turno")["pecas_produzidas"].agg(["sum", "mean", "size"]))
print(producao["pecas_produzidas"].corr(producao["pecas_defeituosas"]))
```

Trecho de referência: variáveis compartilhadas são preparadas no notebook. Use o notebook para copiar e executar o código completo.

## Prática guiada

1. Abra Laboratórios e escolha Produção.
2. Responda às quatro perguntas antes de abrir as resoluções.
3. Reproduza os resultados no notebook.

## Resultado esperado

Os números do painel e do notebook devem coincidir, respeitando arredondamentos.

## Pare e pense

Qual denominador usar para comparar a qualidade total dos turnos?

## Resposta comentada

O total de peças produzidas em cada turno. Divida o total de peças defeituosas desse turno por esse denominador.

Base: Aula 02, páginas 35–48; 51. Explicações, verificações e práticas guiadas são complementos didáticos; resultados usam as bases locais identificadas em Materiais.

TÓPICO 11 · LABORATÓRIOS · PDF 49–50

# Laboratório: eficiência energética das máquinas

## O que você vai aprender

Comparar produção, consumo e eficiência com unidades corretas.

## Mais produção não significa maior eficiência energética.

O exercício traz cinco máquinas com produção por turno e energia por turno. A razão produção dividida por energia expressa peças por quilowatt-hora. O indicador compara o rendimento observado, sem controlar diferenças de produto, capacidade ou carga.

## Médias do exercício

A produção média é 1.318 peças por turno e o consumo médio é 438 kWh por turno. A média das razões não é a razão dos totais em geral.

## Não confunda indicadores

Peças por kWh aumenta quando há mais produção por unidade de energia. kWh por peça é o inverso e melhora quando diminui.

## Conexão com a indústria

A máquina D produz 1.450 peças, o maior volume. A máquina C consome 390 kWh, o menor consumo. A máquina E tem a melhor razão: cerca de 3,259 peças por kWh.

TÓPICO 11 · PRÁTICA E REVISÃO

# Experimente e explique

## Código de referência

```
maquinas = pd.DataFrame({"maquina": ["A","B","C","D","E"],
 "producao": [1250,1380,1190,1450,1320], "energia_kwh": [420,465,390,510,405]})
maquinas["eficiencia"] = maquinas["producao"] / maquinas["energia_kwh"]
print(maquinas.sort_values("eficiencia", ascending=False))
```

Trecho de referência: variáveis compartilhadas são preparadas no notebook. Use o notebook para copiar e executar o código completo.

## Prática guiada

1. Calcule as sete respostas do slide 50.
2. Compare os rankings de produção e eficiência.
3. Explique a unidade do indicador.

## Resultado esperado

Produção: D; menor consumo: C; melhor eficiência: E. Ranking de produção D, B, E, A, C.

## Pare e pense

Por que escolher a máquina de menor consumo pode ser insuficiente?

## Resposta comentada

Ela pode produzir menos. Para avaliar a relação entre saída e consumo, compare peças por kWh, além de capacidade e requisitos de qualidade.

Base: Aula 02, páginas 49–50. Explicações, verificações e práticas guiadas são complementos didáticos; resultados usam as bases locais identificadas em Materiais.

TÓPICO 12 · LABORATÓRIOS · PDF 52–56

# Laboratório: viagens, tempo e vendas

## O que você vai aprender

Resolver as questões de logística e vendas com agrupamentos temporais.

## Análise temporal exige datas válidas e agregações consistentes.

Na logística, investigue total de viagens, maior valor diário, média diária, agregação mensal e relação com distância. Nas vendas, calcule unidades, faturamento e evolução anual. As 100 linhas de vendas são meses, não dias; as de logística são datas diárias.

## Nomeie a média

Média por registro é média diária apenas quando cada dia tem um registro e a cobertura do período está adequada. Verifique duplicação de datas e lacunas.

## Entrega

O material solicita notebook Google com códigos e respostas dos exercícios 1, 2 e 3. Confira os requisitos no slide 56; o campus não envia atividades automaticamente.

## Conexão com a indústria

base_p52.csv contém viagens e distância. base_p54.csv registra meses, preço, unidades e faturamento de um produto. A correlação entre preço e vendas pode refletir tendência temporal e não um efeito isolado do preço.

TÓPICO 12 · PRÁTICA E REVISÃO

# Experimente e explique

## Código de referência

```
viagens = pd.read_csv("base_p52.csv", parse_dates=["data"])
viagens["mes"] = viagens["data"].dt.to_period("M")
print(viagens.groupby("mes")["quantidade_viagens"].sum())
vendas = pd.read_csv("base_p54.csv")
vendas["mes"] = pd.to_datetime(vendas["mes"], format="%Y-%m")
print(vendas.groupby(vendas["mes"].dt.year)["unidades_vendidas"].sum())
```

Trecho de referência: variáveis compartilhadas são preparadas no notebook. Use o notebook para copiar e executar o código completo.

## Prática guiada

1. Resolva as cinco perguntas de viagens.
2. Resolva as cinco perguntas de vendas.
3. Compare os resultados com as resoluções dos laboratórios.

## Resultado esperado

Resultados reproduzíveis, datas convertidas e interpretação que reconhece os limites da correlação.

## Pare e pense

O mês de maior faturamento precisa ser o mês de maior quantidade vendida?

## Resposta comentada

Não. Faturamento depende da quantidade e do preço. Compare os dois e confira a consistência da multiplicação.

Base: Aula 02, páginas 52–56. Explicações, verificações e práticas guiadas são complementos didáticos; resultados usam as bases locais identificadas em Materiais. Atenção: as imagens das tabelas nos slides 52 e 54 aparecem trocadas em relação aos enunciados. Identifique a base pelos nomes das colunas: viagens e distância para logística; preço, unidades e faturamento para vendas.

TÓPICO 13 · PROJETO · PDF 57–72

# Projeto S&M: exploração e preparação

## O que você vai aprender

Preparar as etapas 1 e 2 do projeto com um relatório auditável.

## O projeto começa pela confiabilidade dos registros e pela definição de falha.

O caso S&M Industry apresenta cinco máquinas e registros de sensores. As duas primeiras etapas pedem compreender variáveis, distribuição, frequência de falhas, ausências, duplicatas e relações entre condições operacionais e falha. A taxa de registros com falha não é automaticamente uma taxa de incidentes independentes.

## Perguntas da exploração

Conte registros e atributos, identifique tipos e distribuições e calcule o percentual de registros com falha por máquina.

## Tratamento documentado

Mantenha o arquivo bruto, registre decisões sobre duplicatas e faltantes e investigue extremos. Não use a variável falha para preencher sensores.

## Conexão com a indústria

A base bruta possui 5.050 registros. Antes de comparar máquinas, deduplique de forma justificada, conte faltantes e informe se a análise usa a base bruta ou tratada. O painel do projeto explicita esse recorte.

# Experimente e explique

## Código de referência

```
base = pd.read_csv("manutencao.csv").drop_duplicates().copy()
base["timestamp"] = pd.to_datetime(base["timestamp"], errors="raise")
perfil = base.groupby("maquina_id")["falha"].agg(["size", "sum", "mean"])
print(perfil)
print(base.isna().sum())
```

Trecho de referência: variáveis compartilhadas são preparadas no notebook. Use o notebook para copiar e executar o código completo.

## Prática guiada

1. Abra Projeto industrial e leia as cinco etapas.
2. Execute o diagnóstico do notebook.
3. Registre três achados, suas limitações e uma próxima investigação.

## Resultado esperado

Um diagnóstico com proveniência, regras de tratamento e taxas por equipamento.

## Pare e pense

É correto interpretar 20 registros consecutivos com falha como 20 paradas distintas?

## Resposta comentada

Não necessariamente. Podem ser leituras repetidas durante o mesmo evento. Para contar paradas, é preciso uma definição de episódio e uma regra temporal.

Base: Aula 02, páginas 57–72. Explicações, verificações e práticas guiadas são complementos didáticos; resultados usam as bases locais identificadas em Materiais.

TÓPICO 14 · PROJETO · PDF 73–80

# Projeto S&M: modelos, agrupamentos e escala

## O que você vai aprender

Planejar avaliação, interpretar agrupamentos e justificar uso de PySpark.

## O modelo apoia a decisão quando a avaliação representa o uso real.

As etapas finais pedem classificação supervisionada, K-Means e processamento com PySpark. Compare pelo menos dois classificadores com uma referência simples e métricas adequadas. Separe treino e teste antes de aprender transformações. Em dados temporais, evite que observações futuras ou instantes repetidos vazem para o treino.

## Três etapas, três objetivos

Classificação estima o rótulo; K-Means descreve perfis após escala das variáveis; Spark executa transformações e agregações distribuídas. Um resultado não substitui o outro.

## Entregáveis e avaliação

O slide 79 solicita notebook com as cinco etapas, gráficos, interpretações e recomendações. O slide 80 distribui 100 pontos entre exploração, tratamento, análise, modelos, agrupamentos, Spark e recomendações.

## Conexão com a indústria

Um modelo que acerta a classe sem falha na maioria das vezes pode ter recall zero para falhas. Compare precisão, recall, F1 e matriz de confusão, relacionando falsos alarmes e falhas não detectadas ao custo operacional.

TÓPICO 14 · PRÁTICA E REVISÃO

# Experimente e explique

## Código de referência

```
from sklearn.pipeline import make_pipeline
from sklearn.impute import SimpleImputer
from sklearn.ensemble import RandomForestClassifier
# X_treino e y_treino devem vir de uma separação documentada.
modelo = make_pipeline(SimpleImputer(strategy="median"),
 RandomForestClassifier(n_estimators=100, random_state=42, class_weight="balanced"))
# modelo.fit(X_treino, y_treino)
# Compare previsões no teste com uma referência majoritária.
```

Trecho de referência: variáveis compartilhadas são preparadas no notebook. Use o notebook para copiar e executar o código completo.

## Prática guiada

1. Escolha pelo menos dois classificadores e uma estratégia de validação.
2. Defina como comparar candidatos a K e interpretar perfis.
3. Documente uma agregação em PySpark e as limitações do projeto.

## Resultado esperado

Um roteiro completo e executável com justificativas; não há promessa de um modelo vencedor sem avaliação.

## Pare e pense

Um cluster com mais falhas é automaticamente um modo de falha comprovado?

## Resposta comentada

Não. É um agrupamento estatístico de condições observadas. A interpretação exige domínio, estabilidade e investigação; o rótulo falha não deve ser usado como entrada para construir os clusters.

Base: Aula 02, páginas 73–80. Explicações, verificações e práticas guiadas são complementos didáticos; resultados usam as bases locais identificadas em Materiais.

# Projeto industrial: roteiro de entrega

## 1. Compreensão e exploração dos dados

Dicionário dos oito atributos, estatísticas, visualizações e contagens de falha; informe a versão bruta ou tratada.

## 2. Preparação e mineração de dados

Relatório de qualidade antes/depois e hipóteses apoiadas por tabelas e gráficos.

## 3. Machine Learning supervisionado

Comparação entre Árvore de Decisão, Random Forest ou Regressão Logística, matriz de confusão e justificativa da escolha.

## 4. Machine Learning não supervisionado

Comparação de candidatos a K, perfis dos clusters e análise posterior das taxas de falha.

## 5. Big Data e tomada de decisão

Notebook com as cinco etapas, transformações e agregações em Spark, gráficos e recomendações técnicas.

# Critérios e fontes

## Avaliação do professor · slide 80

Exploração e compreensão dos dados: 15 pontos

Preparação e tratamento: 15 pontos

Análise exploratória e mineração: 15 pontos

Machine Learning supervisionado: 25 pontos

Machine Learning não supervisionado: 10 pontos

Big Data com PySpark: 10 pontos

Interpretação e recomendações: 10 pontos

Total: 100 pontos. O notebook deve conter as cinco etapas, gráficos, interpretações e recomendações. O campus não submete atividades.

## Documentação técnica

Pandas: pandas.pydata.org/docs/getting_started/intro_tutorials/

Scikit-learn: scikit-learn.org/stable/common_pitfalls.html

PySpark: spark.apache.org/docs/latest/api/python/getting_started/quickstart_df.html

## Limites da análise

Associação não demonstra causa. Classificar o rótulo atual não comprova previsão antecipada de parada. Duplicar dados cria volume sintético, não evidência nova. O notebook registra suas transformações e a estratégia de avaliação.