Pós Graduação
Data Science e Big Data na Indústria

Disciplina: Data Science e Big Data

Aula 01

Prof. Me Daniel Vieira

UNISENAI
Inovação no Ensino Superior para a Indústria

Apresentação

Doutorando e Mestre em Engenharia Elétrica - FEEC / Unicamp

Engenheiro Eletricista - UniMetrocamp Wyden

Técnico de Mecatrônica - Senai Roberto Mange

Áreas de atuação :

Projetos eletrônicos

Hardware e firmware

Desenvolvimento de aplicativos C++, C#, Python, Mobile

Análise de dados

Pesquisa com IA multimodal, Machine Learning, Lógica Fuzzy

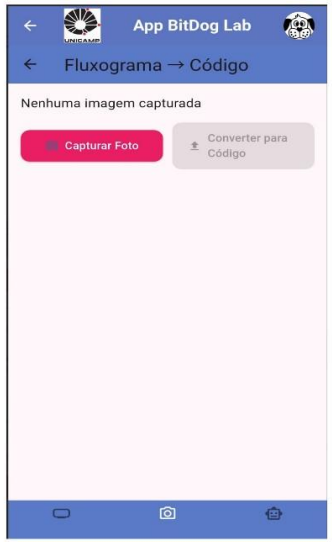
Projetos desenvolvidos



a)



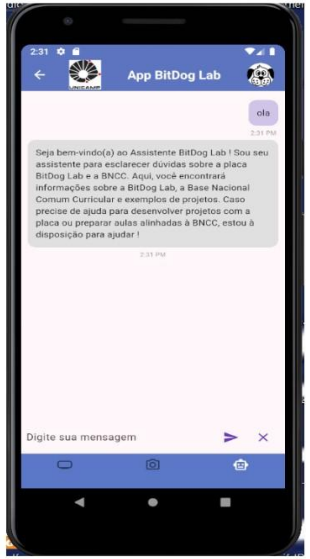
b)



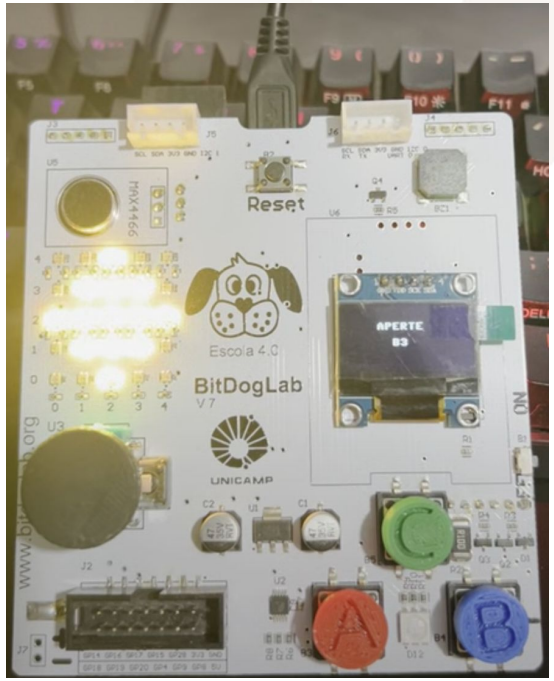
c)



d)



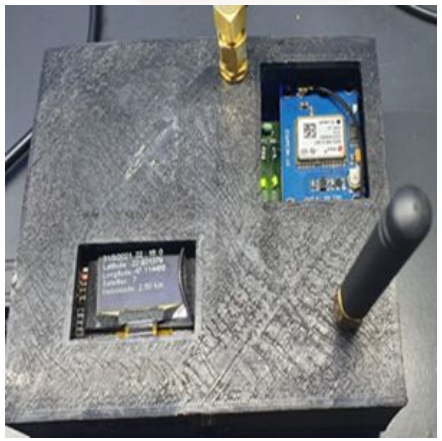
e)



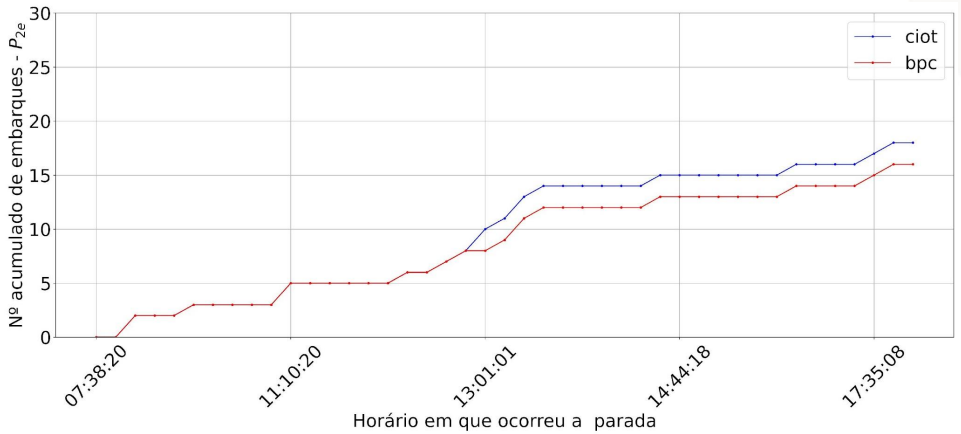
UNISENAI | Inovação no Ensino Superior para a Indústria

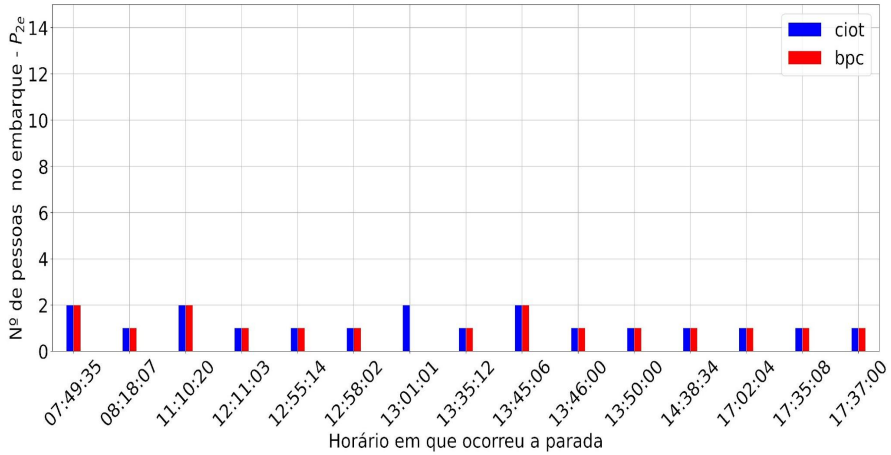
Projetos desenvolvidos

Monitoramento de pessoas e monitoramento por GPS



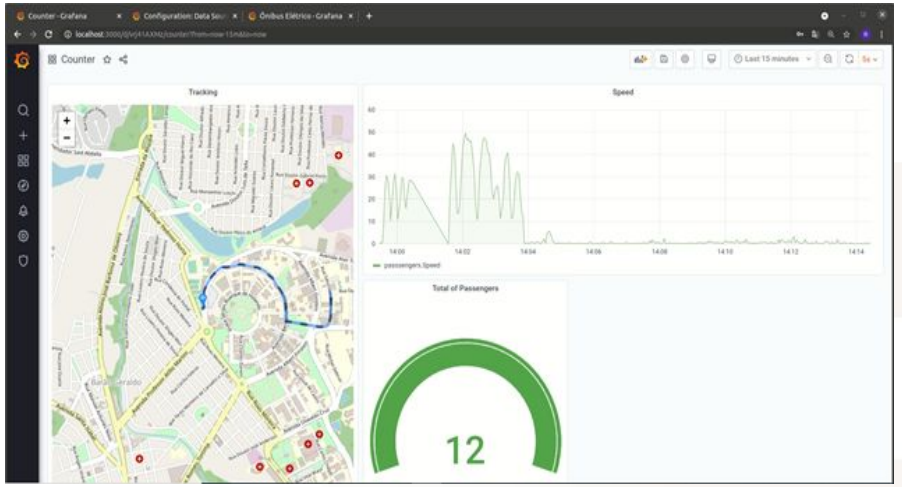






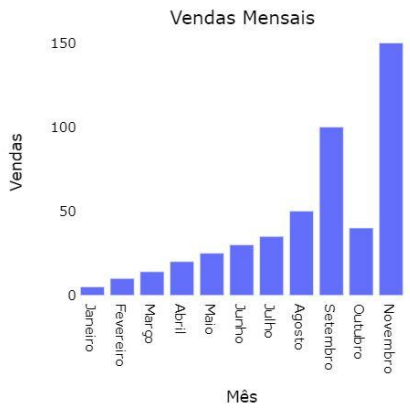
UNISENAI

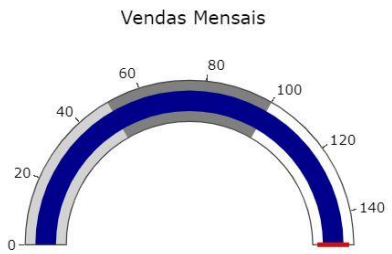
Inovação no Ensino Superior para a Indústria



Projetos desenvolvidos

Dashboard com Plotly





Mês	Vendas
1	5
2	10
3	14
4	20
5	25
6	30
7	35
8	50
9	100
10	40

Classificação de transação com cartão de crédito

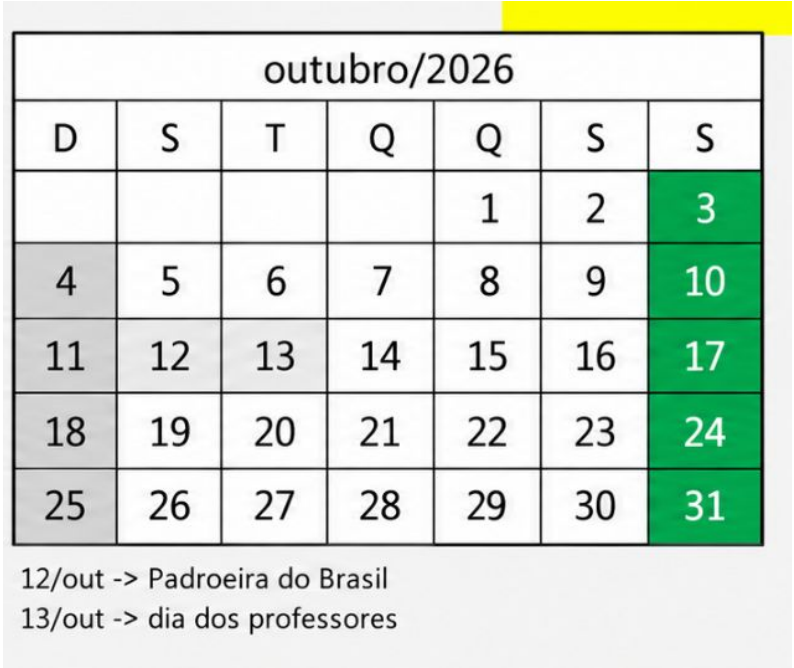


UNISENAI Inovação no Ensino Superior para a Indústria

Disciplinas do Curso de Pós Graduação

Módulos	Unidade Curricular	Carga Horária(H)
1º Semestre Fundamentos	Data Science e BIG DATA	30
	Linguagem R para Data Science	30
	Linguagem Python para Data Science	30
	Inteligência Artificial para Data Science	30
2 º Semestre Aplicações	Aprendizagem Estatística	30
	IIOT (Industrial Internet of Things)	30
	Machine Learning com Aplicações Industriais	30
	Computação em Nuvem	30
3º Semestre Avançado	Deep Learning aplicado na indústria	30
	Business Analytics Aplicado na Indústria	30
	Visual Analytics Aplicado na Indústria	30
	Metodologia do Trabalho Científico	30

Calendário



outubro/2026						
D	S	T	Q	Q	S	S
				1	2	3
4	5	6	7	8	9	10
11	12	13	14	15	16	17
18	19	20	21	22	23	24
25	26	27	28	29	30	31

12/out -> Padroeira do Brasil
13/out -> dia dos professores

Outubro - Disciplina Data Science e Big Data na Indústria

UNISENAI Inovação no Ensino Superior para a Indústria

Metodologia

Horário das aulas : 9:30 às 16:30
Almoço: 12:00 - 13:00
Intervalo 1: 11:00 - 11:15
Intervalo 2: 15:15 - 15:30

Metodologia: Aulas expositivas, projetos , estudo de caso
Nota mínima: 70

Data Science e Big Data na Indústria

Objetivo: Desenvolver a competência para a aplicação de técnicas modernas de Big Data, Mineração de Dados e Aprendizagem de máquina em ambientes industriais.

Data Science e Big Data na Indústria



UNISENAI

Inovação no
Ensino Superior
para a Indústria

Data Science e Big Data na Indústria

Referências básicas

HURWITZ, J. et al. Big Data Para Leigos. Rio de Janeiro: Alta Books, 2016.

TAN, P.; STEINBACH, M.; KUMAR, V. Introdução ao Data Mining - Mineração de Dados. Rio de Janeiro: Ciência Moderna, 2009.

PIERSON, L. Data Science Para Leigos. Rio de Janeiro: Alta Books, 2019.

Data Science e Big Data na Indústria

Referências bibliográficas complementares

GRUS, J. Data Science do Zero. Rio de Janeiro: Alta Books, 2016.

FAWCETT, T.; PROVOST, F. Data Science para negócios. Rio de Janeiro: Alta Books, 2016.

FOREMAN, J. W. Data Smart. Usando Data Science Para Transformar Informação em Insight. Rio de Janeiro: Alta Books, 2016.

AMARAL, F. Introdução à Ciência de Dados: mineração de dados e big data. Rio de Janeiro: Alta Books, 2016.

Data Science e Big Data na Indústria

Onde uma empresa industrial pode gerar dados ?

Fontes de dados em uma indústria



UNISENAI
Inovação no Ensino Superior para a Indústria

“É possível identificar sinais de falha antes de a máquina parar?”

Sinais que uma máquina apresenta antes de parar

1

Sobrecorrente

Aumento anormal da corrente.



2

Aquecimento

Elevação da temperatura.



3

Vibração

Vibração acima do normal.





Parada da máquina

Esses sinais podem indicar **falha iminente** e justificar **manutenção preditiva.**

UNISENAI

Inovação no Ensino Superior para a Indústria

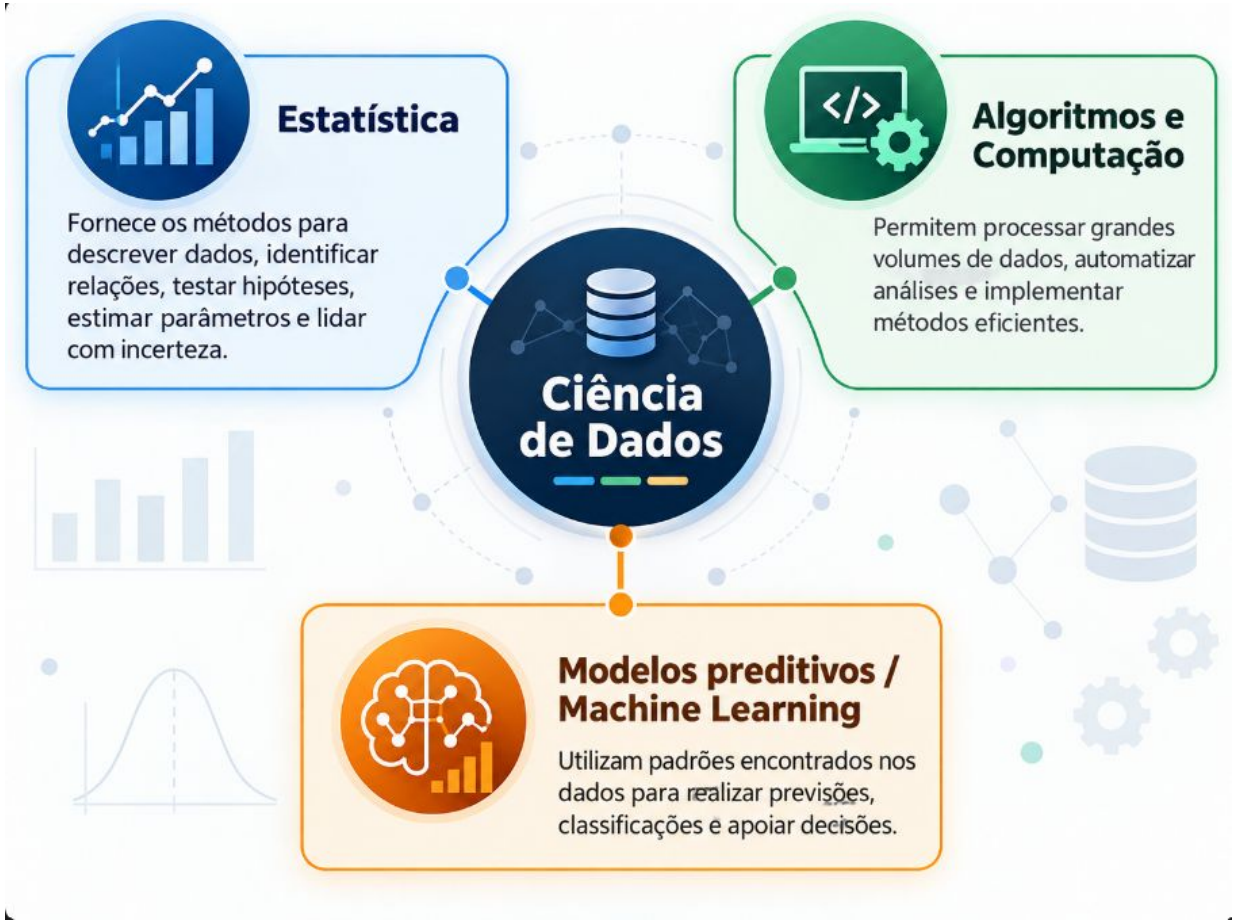
Data Science (Ciência de Dados)



Data Science (Ciência de Dados)



Data Science (Ciência de Dados)



Tipos de profissionais de Data Science (Ciência de Dados)



Data Mining (Mineração de Dados)

Mineração de dados surgiu nos anos de 1990 e se consolidou com o conceito de tecnologia da Informação.
Bruce Greenwald e Joseph Stiglitz.
A informação passou a ser utilizada como um diferencial para extrair insights para melhorar decisões.

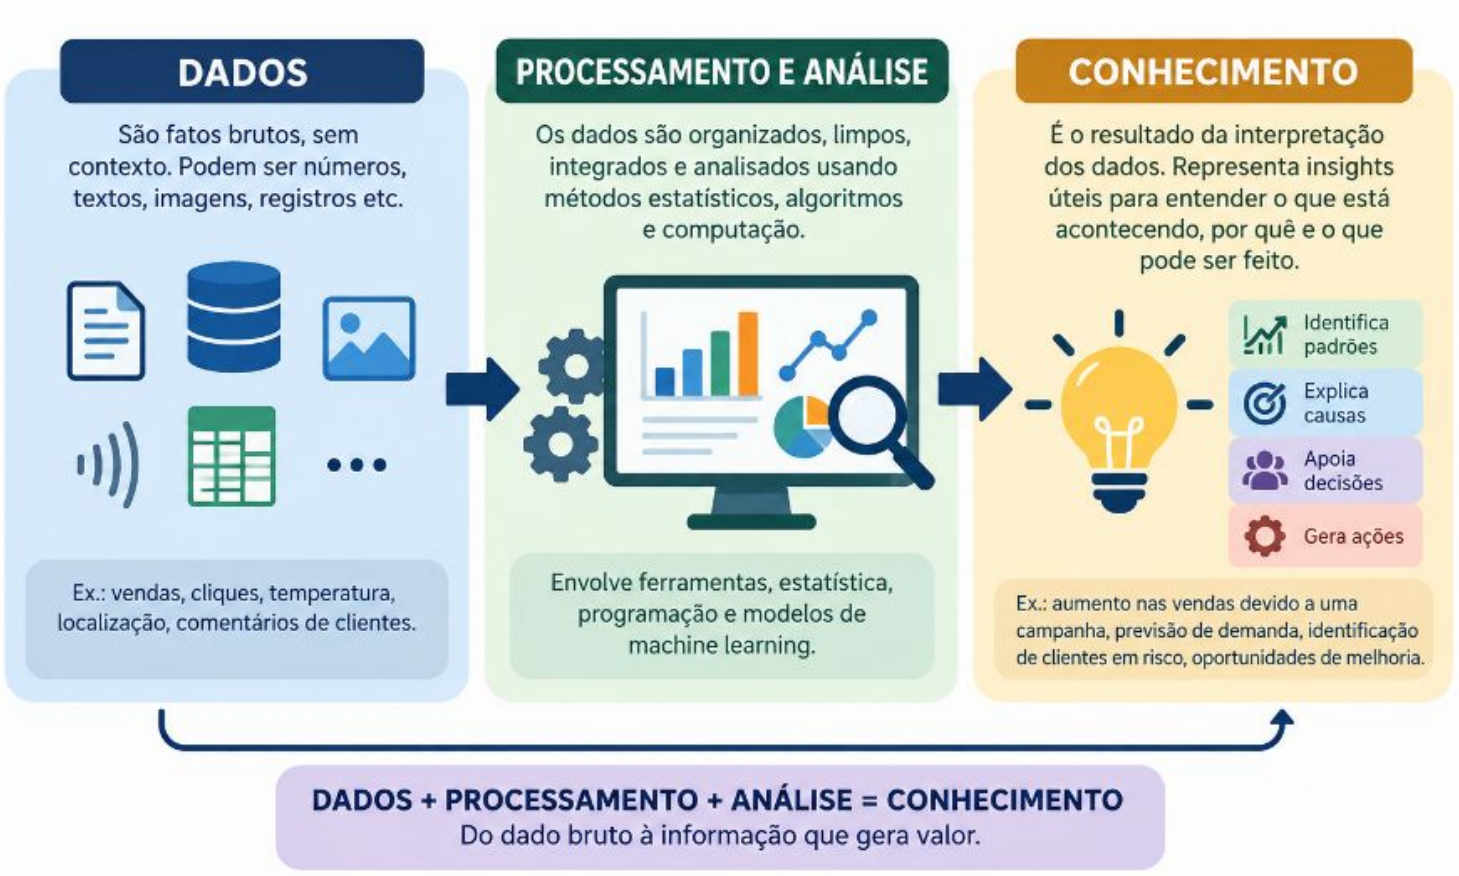


Data Mining (Mineração de Dados)

Análise exploratória
Análise estatística
Mineração de dados



Data Mining (Mineração de Dados)



Data Mining (Mineração de Dados)

Dados de máquinas, produção, qualidade e manutenção



Máquinas
- Sensores (vibração, temperatura, etc.)
- Estado operacional

Produção
- Quantidade produzida
- Tempo de ciclo

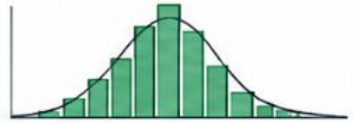
Qualidade
- Defeitos
- Medições de processo

Manutenção
- Ordens de serviço
- Histórico de intervenções

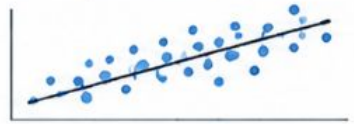
Análise estatística



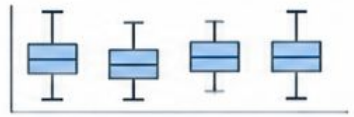
Análise de séries temporais



Distribuição de dados



Correlação de variáveis



Identificação de padrões e outliers

Algoritmos

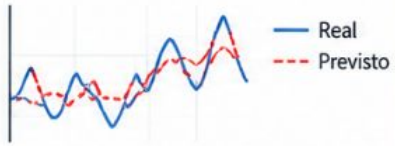
Aprendizado de máquina
- Regressão
- Árvores de decisão
- Random Forest
- Gradient Boosting

Redes neurais
- Deep Learning
- LSTM (séries temporais)

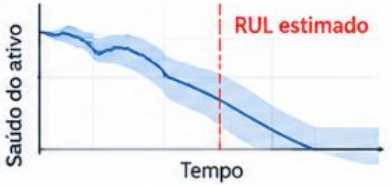
Agrupamento
- K-means
- Segmentação de ativos

Outros algoritmos
- Detecção de anomalias
- Regressão logística
- SVM, etc.

Modelos preditivos



Previsão de falhas



Vida útil restante (RUL)



Probabilidade de defeitos / desvios

Tomada de decisão

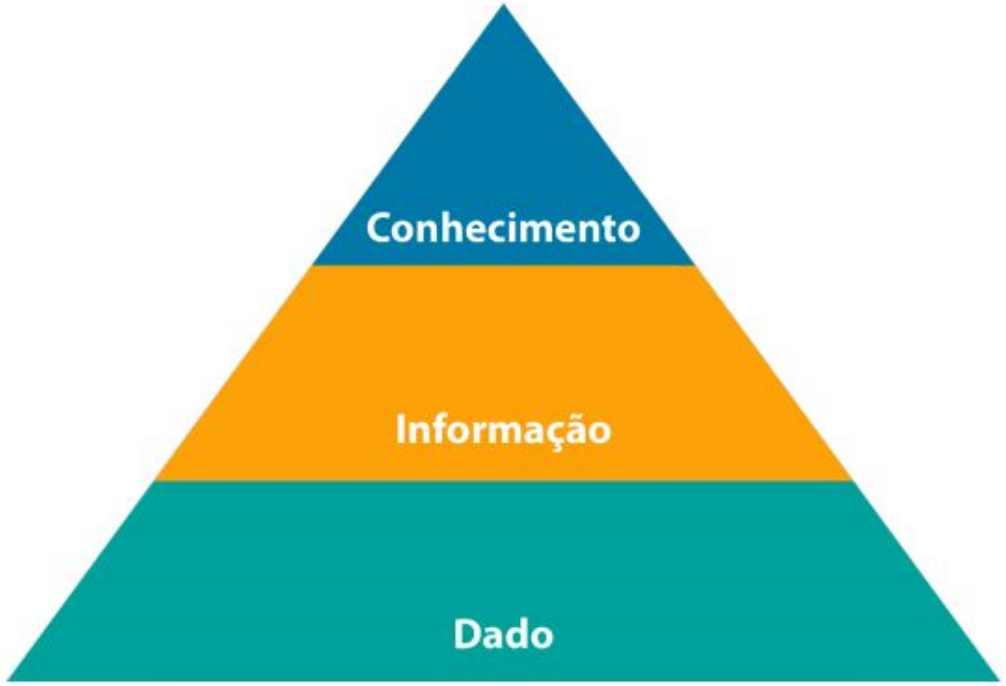
Manutenção preditiva
- Agendar intervenções
- Evitar falhas

Otimização da produção
- Aumentar eficiência
- Reduzir paradas

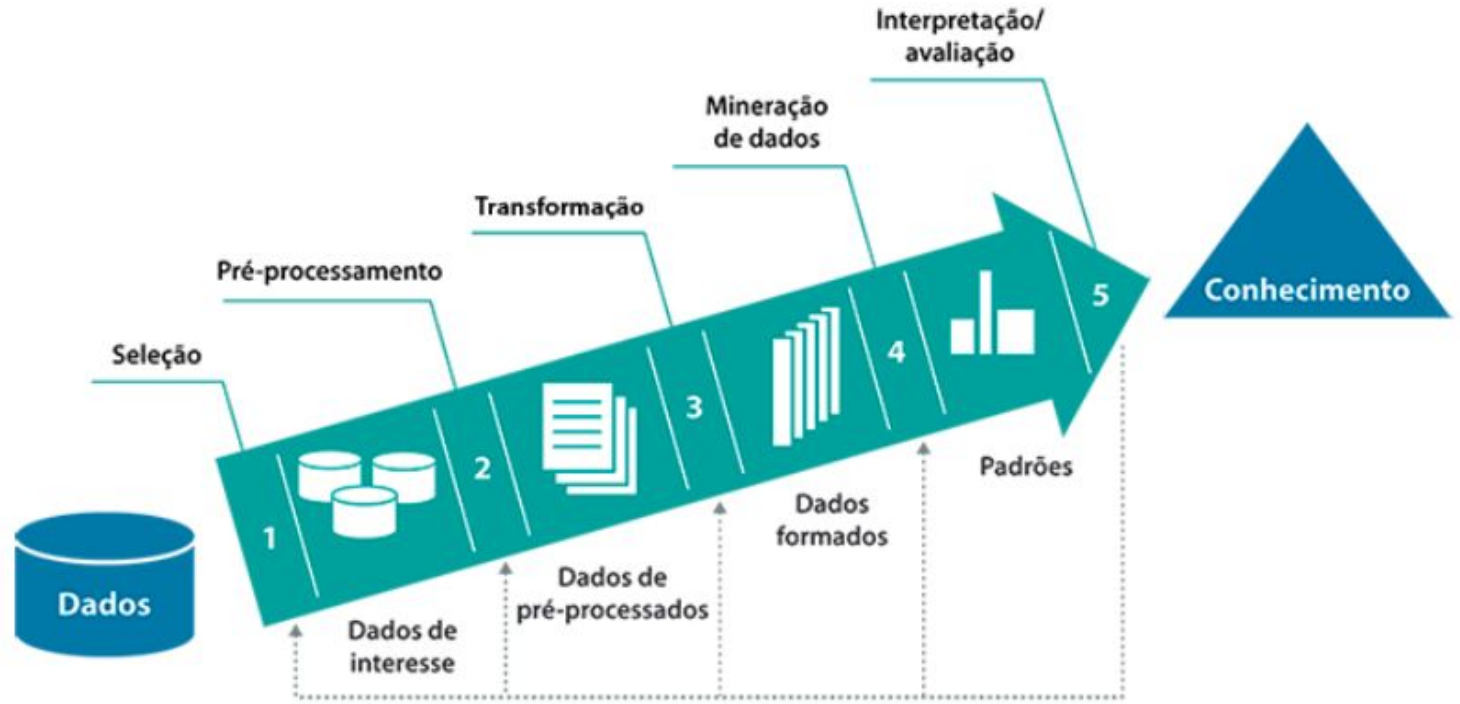
Controle de qualidade
- Ações corretivas
- Reduzir defeitos

Decisões estratégicas
- Planejamento de recursos
- Investimentos em ativos

Processo KDD - Knowledge Discovery in Database

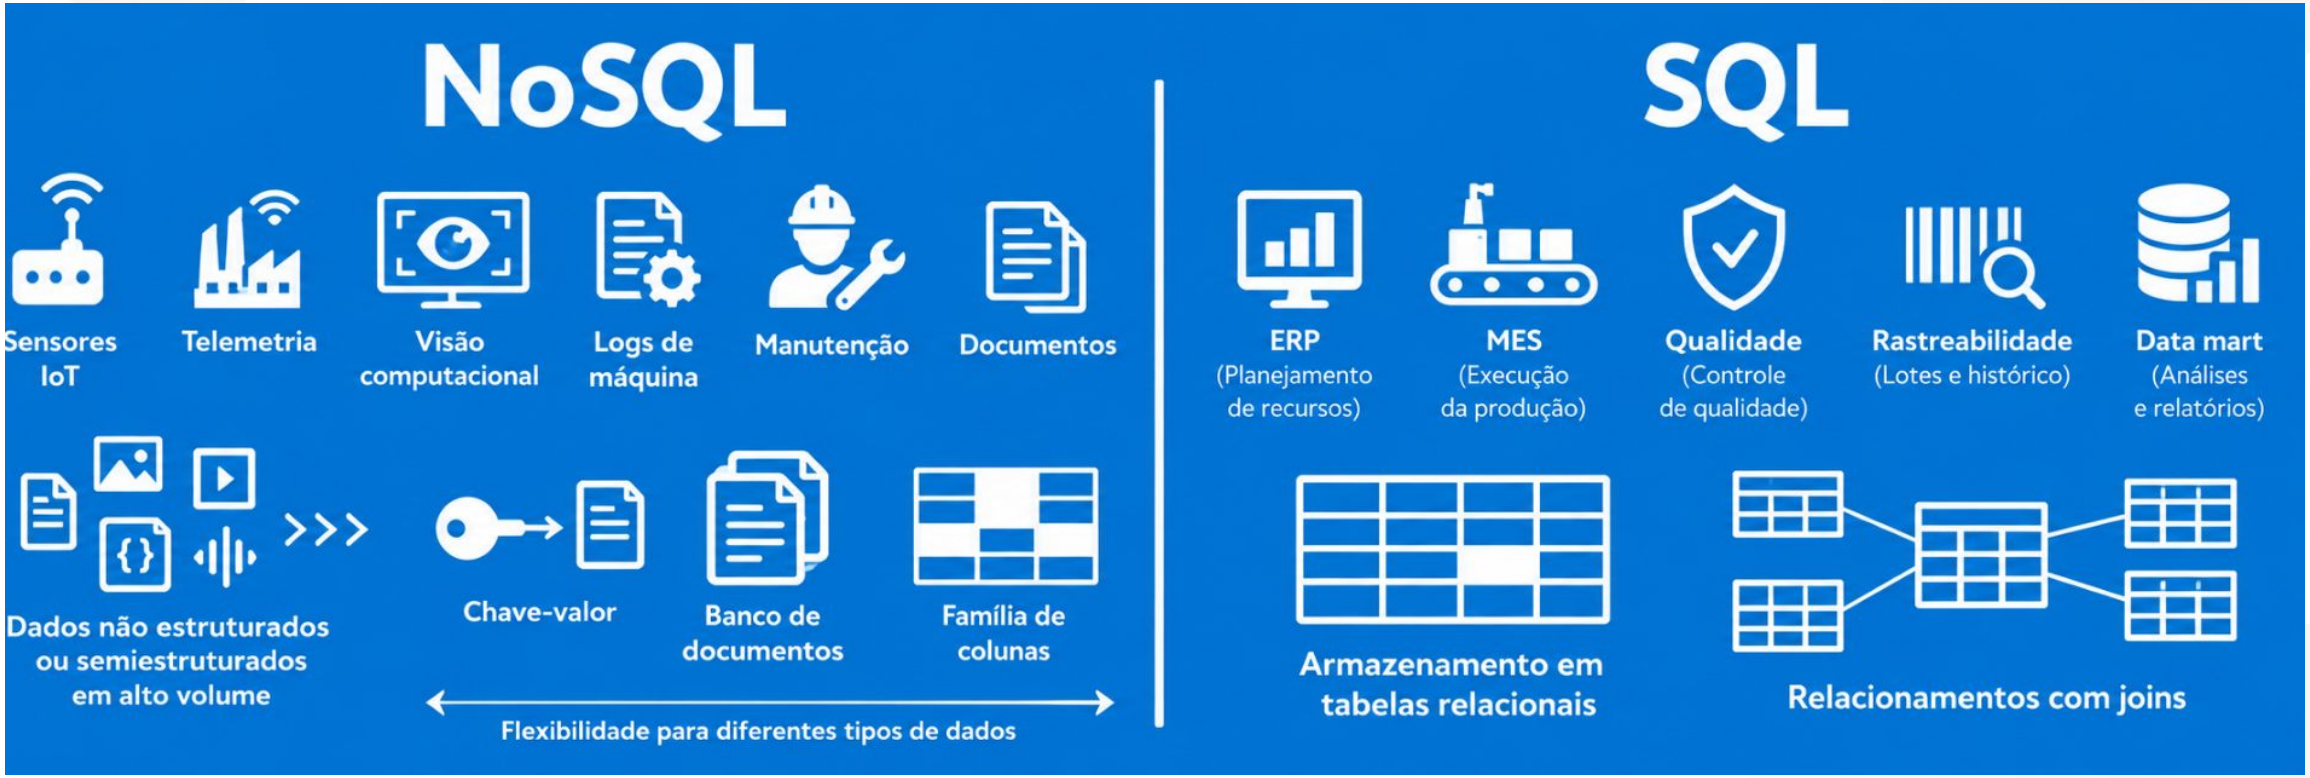


Processo KDD - Knowledge Discovery in Database



Processo KDD - Knowledge Discovery in Database

1- Seleção dos dados



Processo KDD - Knowledge Discovery in Database

2- Pré processamento

Dados NAN
Dados inválidos
Dados não estruturados



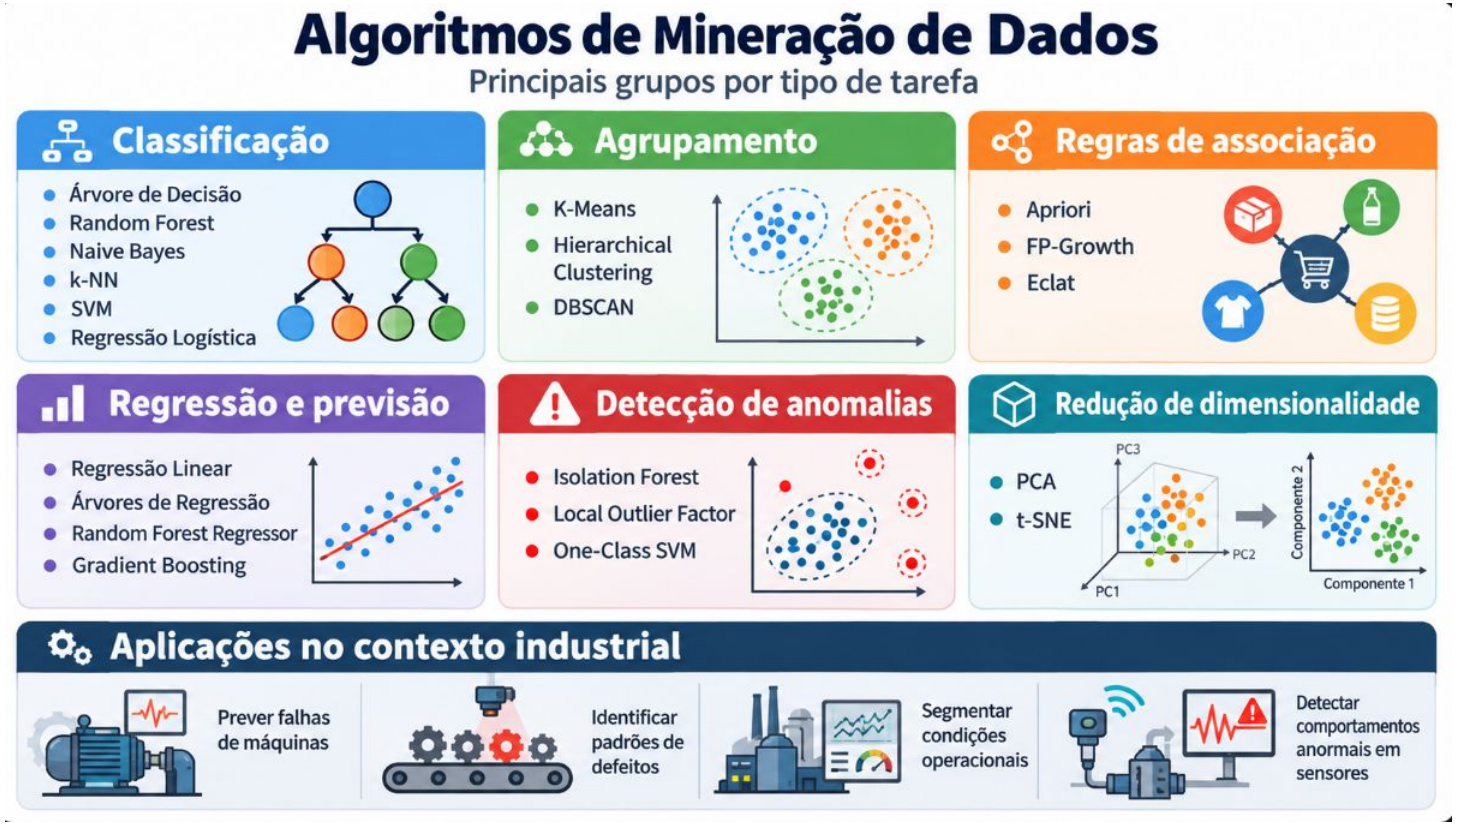
Processo KDD - Knowledge Discovery in Database

3- Transformação

Os dados pré-processados são transformados de acordo com a fase posterior, pois alguns algoritmos de aprendizado podem não ser capazes de lidar com atributos em determinados formatos. Outro exemplo comum é a normalização dos dados, que proporciona melhores resultados para alguns
algoritmos. Após transformados, os dados são reorganizados e armazenados para que possam ser interpretados na etapa seguinte.

Processo KDD - Knowledge Discovery in Database

4- Mineração de dados

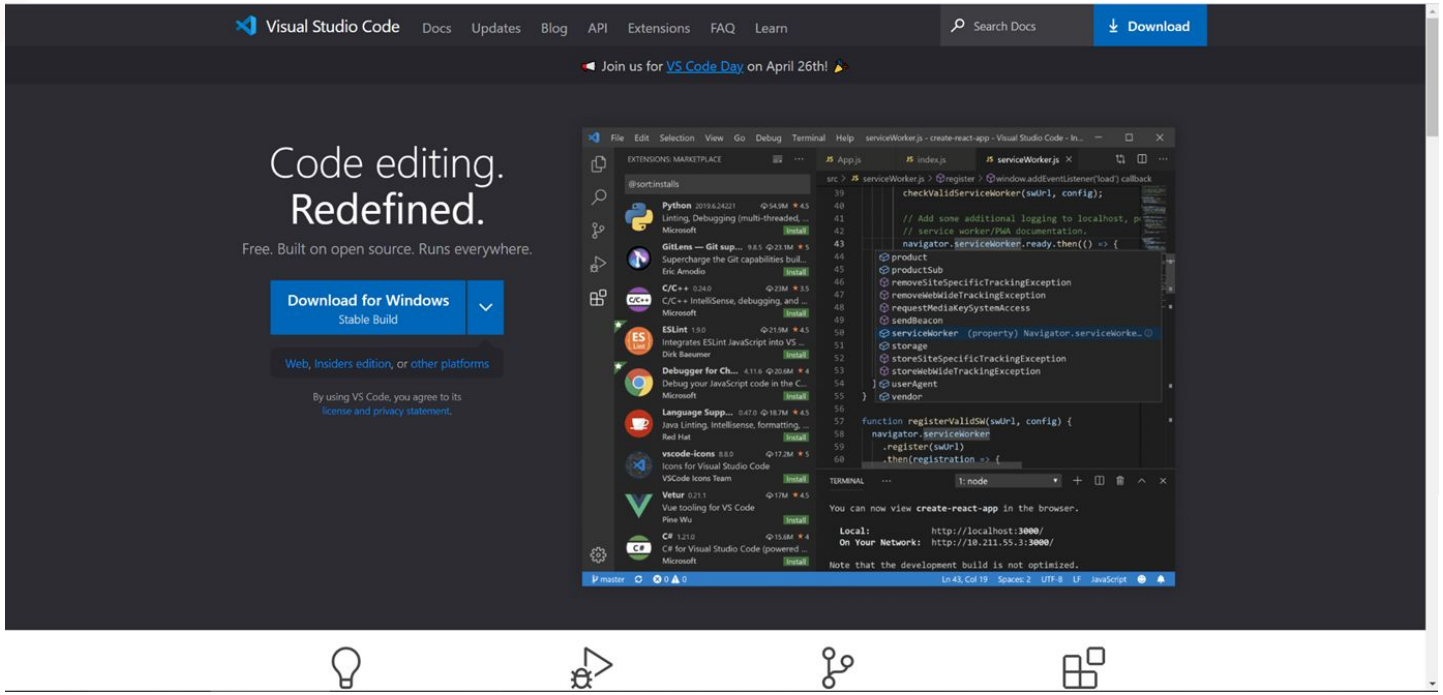


Processo KDD - Knowledge Discovery in Database

5- Interpretação e avaliação

As informações serão interpretadas a fim de se verificar se são válidas ao problema proposto.
Serão avaliados os padrões descobertos e traduzidos em termos inteligíveis para os usuários,gerando conhecimento ao domínio. Também podem ser descobertos padrões irrelevantes ou redundantes que podem ser desconsiderados e removidos. O conhecimento descoberto deverá ser incorporado ao desempenho e partes interessadas do sistema gerando conhecimento ao domínio. Também podem ser descobertos padrões irrelevantes ou redundantes que podem ser desconsiderados e removidos. O conhecimento descoberto deverá ser incorporado ao desempenho e partes interessadas do sistema.

Recursos utilizados para Data Science

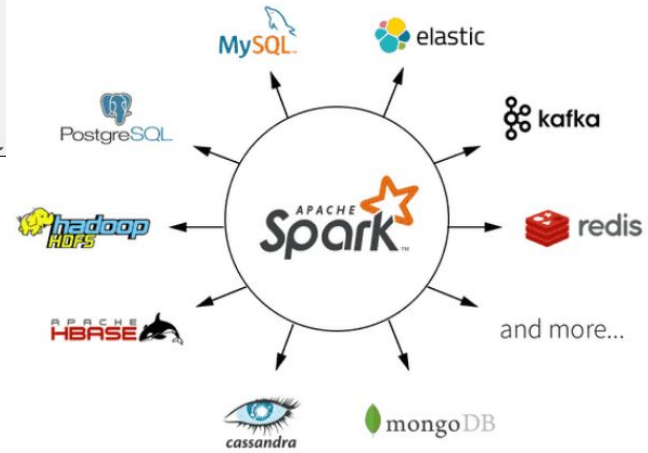












UNISENAI Inovação no Ensino Superior para a Indústria

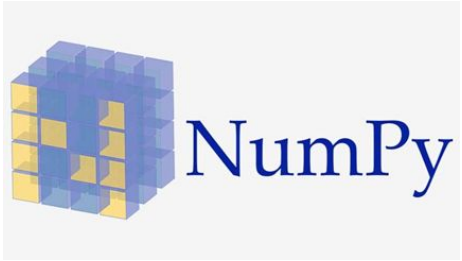
Principais bibliotecas utilizadas para Data Science













Exercício

Questionário

Biblioteca Pandas

A biblioteca Pandas é uma biblioteca responsável por realizar a leitura de arquivos externos no formato csv, xlsx, parquet.



Biblioteca Pandas

Limpeza, tratamento de dados, análise exploratória dos dados, suporte em atividades de Machine Learning, consultas, queries em bancos de dados, visualização de dados, web scraping e etc

Biblioteca Pandas

Séries e Dataframes

As séries são arrays unidimensionais e com um eixo de rótulos chamado index

```
0      1.4
1      1.4
2      1.3
3      1.5
4      1.4
      ...
145    5.2
146    5.0
147    5.2
148    5.4
149    5.1
```

Biblioteca Pandas

Dataframes - são objetos bidimensionais de tamanho variável. Formato de tabela

produto	producao	defeitos	temperatura
Motor A	100	5	70
Motor B	120	12	82
Motor A	110	6	73
Motor C	90	3	68
Motor B	130	15	85

Biblioteca Pandas - Instalação

pip install pandas

Caso não tenha o pacote pip instalado na máquina instalar o pacote pip

python -m ensurepip –upgrade

```
# importando a biblioteca pandas
import pandas as pd
```

Biblioteca Pandas - Principais funções

Comando	Para que serve
`pd.DataFrame()`	Cria um DataFrame
`pd.read_csv()`	Lê arquivo CSV
`pd.read_excel()`	Lê arquivo Excel
`df.head()`	Mostra as primeiras linhas
`df.tail()`	Mostra as últimas linhas
`df.shape`	Mostra quantidade de linhas e colunas

Biblioteca Pandas - Principais funções

`df.columns`	Mostra os nomes das colunas
`df.info()`	Mostra tipos de dados e valores nulos
`df.describe()`	Estatísticas descritivas
`df["coluna"]`	Seleciona uma coluna
`df[["col1","col2"]]`	Seleciona várias colunas
`df.loc[]`	Seleção por rótulo/condição
`df.iloc[]`	Seleção por posição

Biblioteca Pandas - Principais funções

`df.query()`	Filtra usando expressão
`df.sort_values()`	Ordena os dados
`df.groupby()`	Agrupa os dados
`df.value_counts()`	Conta ocorrências
`df.mean()`	Calcula média
`df.sum()`	Calcula soma
`df.min()`	Retorna mínimo
`df.max()`	Retorna máximo

Biblioteca Pandas - Principais funções

`df.median()`	Calcula mediana
`df.std()`	Calcula desvio padrão
`df.isnull()`	Verifica valores nulos
`df.dropna()`	Remove valores nulos
`df.fillna()`	Preenche valores nulos
`df.drop()`	Remove linhas ou colunas
`df.rename()`	Renomeia colunas
`df.astype()`	Altera o tipo de dado
`df["nova"] = ...`	Cria nova coluna

Biblioteca Pandas - Principais funções

`pd.concat()`	Junta DataFrames
`pd.merge()`	Faz junção entre tabelas
`df.corr()`	Calcula correlação
`df.to_csv()`	Salva em CSV
`df.to_excel()`	Salva em Excel

Exercício : Será que o aumento de defeitos está relacionado ao aumento da temperatura ?

produto	producao	defeitos	temperatura
Motor A	100	5	70
Motor B	120	12	82
Motor A	110	6	73
Motor C	90	3	68
Motor B	130	15	85

Exercício : Será que o aumento de defeitos está relacionado ao aumento da temperatura ?

```
import pandas as pd

dados = {
    "produto": ["Motor A", "Motor B", "Motor A", "Motor C", "Motor B"],
    "producao": [100, 120, 110, 90, 130],
    "defeitos": [5, 12, 6, 3, 15],
    "temperatura": [70, 82, 73, 68, 85]
}

df = pd.DataFrame(dados)
```

Exercício 1

1 - Visualizar os dados

```
1 df.head()
```

	produto	producao	defeitos	temperatura
0	Motor A	100	5	70
1	Motor B	120	12	82
2	Motor A	110	6	73
3	Motor C	90	3	68
4	Motor B	130	15	85

```
1 df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5 entries, 0 to 4
Data columns (total 4 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   produto      5 non-null      object
 1   producao     5 non-null      int64
 2   defeitos     5 non-null      int64
 3   temperatura  5 non-null      int64
dtypes: int64(3), object(1)
memory usage: 292.0+ bytes
```

Exercício 1

1 - Visualizar os dados

```
1 df.describe()
```

	producao	defeitos	temperatura
count	5.000000	5.000000	5.000000
mean	110.000000	8.200000	75.600000
std	15.811388	5.069517	7.503333
min	90.000000	3.000000	68.000000
25%	100.000000	5.000000	70.000000
50%	110.000000	6.000000	73.000000
75%	120.000000	12.000000	82.000000
max	130.000000	15.000000	85.000000

Exercício 1

2 - Selecionar uma coluna

```
1 df["temperatura"]
```

	temperatura
0	70
1	82
2	73
3	68
4	85

dtype: int64

UNISENAI
Inovação no
Ensino Superior
para a Indústria

Exercício 1

2 - Selecionar várias colunas

```
1 df[["produto", "temperatura"]]
```

	produto	temperatura
0	Motor A	70
1	Motor B	82
2	Motor A	73
3	Motor C	68
4	Motor B	85

Exercício 1

3 - Filtrar dados

```
1 df[df["temperatura"] > 75]
```

	produto	producao	defeitos	temperatura
1	Motor B	120	12	82
4	Motor B	130	15	85

Exercício 1

3 - Filtrar dados

```
1 df[df["temperatura"] > 75]
```

	produto	producao	defeitos	temperatura
1	Motor B	120	12	82
4	Motor B	130	15	85

```
1 df[
2     (df["temperatura"] > 75) &
3     (df["defeitos"] > 10)
4 ]
```

	produto	producao	defeitos	temperatura
1	Motor B	120	12	82
4	Motor B	130	15	85

Exercício 1

4 - Média

```
1 df["temperatura"].mean()
```

```
np.float64(75.6)
```

```
1 df["producao"].mean()
```

```
np.float64(110.0)
```

```
1 df["temperatura"].max()
```

```
85
```

```
1 df["temperatura"].min()
```

```
68
```

Exercício 1

5 - Maior e menor valor de temperatura

```
1 df["temperatura"].max()
```

```
85
```

```
1 df["temperatura"].min()
```

```
68
```

Exercício 1

6 - Ordenando por maior temperatura para a menor temperatura

```
df.sort_values(
    by="temperatura",
    ascending=False
)
```

	produto	producao	defeitos	temperatura
4	Motor B	130	15	85
1	Motor B	120	12	82
2	Motor A	110	6	73
0	Motor A	100	5	70
3	Motor C	90	3	68

Exercício 1

7 - Agrupar produção média por produto

```
1 df.groupby("produto")["producao"].mean()
```

produto	producao
Motor A	105.0
Motor B	125.0
Motor C	90.0

dtype: float64

Exercício 1

7 - Agrupar defeitos médio por produto

```
1 df.groupby("produto")["defeitos"].mean()
```

produto	defeitos
Motor A	5.5
Motor B	13.5
Motor C	3.0

dtype: float64

Exercício 1

8 - Estatísticas

```
df.groupby("produto").agg({
    "producao": "mean",
    "defeitos": "sum",
    "temperatura": "mean"
})
```

produto	producao	defeitos	temperatura
Motor A	105.0	11	71.5
Motor B	125.0	27	83.5
Motor C	90.0	3	68.0

Exercício 1

9 - Criando outra coluna

```
df["taxa_defeitos"] = (
    df["defeitos"] / df["producao"] * 100
)
```

Exercício 1

10 - Correlação

```
df[[
    "producao",
    "defeitos",
    "temperatura"
]].corr()
```

	producao	defeitos	temperatura
producao	1.000000	0.966863	0.969334
defeitos	0.966863	1.000000	0.995051
temperatura	0.969334	0.995051	1.000000

Exercício 2 - Você tem dados de produção por máquina, consumo de energia

Máquina	Produção (peças/turno)	Energia (kWh/turno)
Máquina A	1250	420
Máquina B	1380	465
Máquina C	1190	390
Máquina D	1450	510
Máquina E	1320	405

Crie o dataframe e responda às seguintes perguntas:

a) Qual máquina produziu mais?
b) Qual máquina consome menos energia?
c) Qual foi a produção média das máquinas?
d) Qual foi o consumo médio de energia?
e)Ordene as máquinas da maior para a menor produção.
f) Crie uma nova coluna chamada eficiência, calculada por: produção/energia(KWh)
g) Qual máquina apresentou a melhor relação entre produção e consumo de energia?

Obrigado !

Prof. Me Daniel Vieira

Email: danielvieira2006@gmail.com

Linkedin: Daniel Vieira

Instagram: Prof daniel.vieira95

